Vilniaus Universitetas

Regresija įvykių skaičiui

Laboratorinis darbas

Darbą atliko:

Vainius Gataveckas, Matas Gaulia, Dovydas Martinkus

Duomenų Mokslas

3 kursas 2 gr.

Vilnius, 2022

Turinys

Naudoti metodai

Darbas atliktas naudojant R ir Python.

Naudoti R paketai:

tidyverse

AER

MASS

rsample

corrplot

effects

yardstick

Naudoti Python paketai:

numpy

pandas

matplotlib

seaborn

statsmodels

Duomenys ir jų šaltiniai

Išnuomotų dviračių skaičius pagal dienos ir oro sąlygų duomenys.

Duomenų šaltinis – Kaggle. Prieiga per internetą:

https://www.kaggle.com/datasets/brajeshmohapatra/bike-count-prediction-data-set?select=train.csv.

“Datetime” – data ir laikas.

“Season” – metų laikas (1 – pavasaris, 2 – vasara, 3- ruduo, 4 - žiema).

“Holiday” – ar diena yra šventė.

“Workingday” – ar diena yra darbo dienas.

“Weather” – kodinis oro sąlygų kintamasis.

“Temp” – temperatūra Celcijaus laipsniais.

“Atemp” – jutiminė temperatūra Celcijaus laipsniais.

“Humidity” – oro drėgnumas.

“Windspeed” – vėjo greitis.

“Casual” – neregistruotų vartotojų išsinuomotų dviračių skaičius.

“Register” - registruotų vartotojų išsinuomotų dviračių skaičius.

“Counts” – bendras išsinuomotų dviračių skaičius (atsako kintamasis).

Tikslas ir uždaviniai

Tikslas: Sudaryti regresijos modelį išnuomotų dviračių skaičiui, įvertinti kokią įtaką tam tikri kintamieji daro dviračių nuomos paklausai, panaudoti sudarytą modelį prognozuoti dviračių paklausą esant tam tikroms sąlygoms.

Uždaviniai:

Sudaryti įvykių skaičiaus regresijos modelius turimai duomenų aibei.

Atlikti sudarytų modelių tinkamumo analizę.

Tinkamiausio modelio parinkimas.

Modelio koeficientų interpretacija.

Modelio panaudojimas prognozuoti dviračių nuomos paklausą esant tam tikroms sąlygoms.

Atliktos analizės aprašymas

1. Naudojant R

Duomenų aibę apskritai sudaro 17379 stebėjimai. Duomenų aibėje nėra praleistų reikšmių. Pasirinkta duomenų aibę sumažinti iki stebėjimų gautų vidurdienį (12-14 valandomis) ir sudaryti modelį dviračių nuomos paklausai tik esant tam dienos laikotarpiui. Duomenys padalinti į mokymo ir testavimo aibes naudojant 90-10 santykį.

```
# Duomenys
# https://www.kaggle.com/datasets/brajeshmohapatra/bike-count-prediction-data-
set?select=train.csv

library(tidyverse)
library(AER)
library(MASS)

tr <- read.csv("train.csv")
te <- read.csv("test.csv")
te$count <- te$casual + te$registered
full <- rbind(tr, te)

full <- full %>%
  dplyr::select(-c(casual, registered)) %>%
  mutate(
    hour = lubridate::hour(datetime)
  )

full <- full %>%
  filter(hour %in% c(12,13,14)) %>%
  dplyr::select(-c(hour,datetime)) %>%
  mutate(
    season = factor(season),
    holiday = factor(holiday),
    workingday = factor(workingday),
    weather = factor(weather)
  )

head(full)

##   season holiday workingday weather  temp  atemp humidity windspeed count
## 1      1       0          0       1 17.22 21.210       77   19.0012    84
## 2      1       0          0       2 18.86 22.725       72   19.9995    94
## 3      1       0          0       2 18.86 22.725       72   19.0012   106
## 4      1       0          0       2 14.76 16.665       66   19.9995    93
## 5      1       0          0       2 14.76 17.425       66    8.9981    75
## 6      1       0          0       3 14.76 17.425       76   12.9980    59

# Perdaromi mokymo ir testavimo duomenų rinkiniai
library(rsample)
full_split <- initial_split(full, prop = 0.9)
train <- training(full_split)
test <- testing(full_split)

write_csv(train,"train_from_R.csv")
write_csv(test,"test_from_R.csv")
```

```r
# Siekiant gauti tokius pat rezultatus duomenys nuskaitomi iš failų
train <- read_csv("train_from_R.csv")

test <- read_csv("test_from_R.csv")

train <- train %>%
    mutate(
    season = factor(season),
    holiday = factor(holiday),
    workingday = factor(workingday),
    weather = factor(weather)
  )

test <- test %>%
    mutate(
    season = factor(season),
    holiday = factor(holiday),
    workingday = factor(workingday),
    weather = factor(weather)
  )


min(test$count)

## [1] 12



ggplot(train, aes(x = count)) +
  geom_histogram() +
  theme_minimal()
```

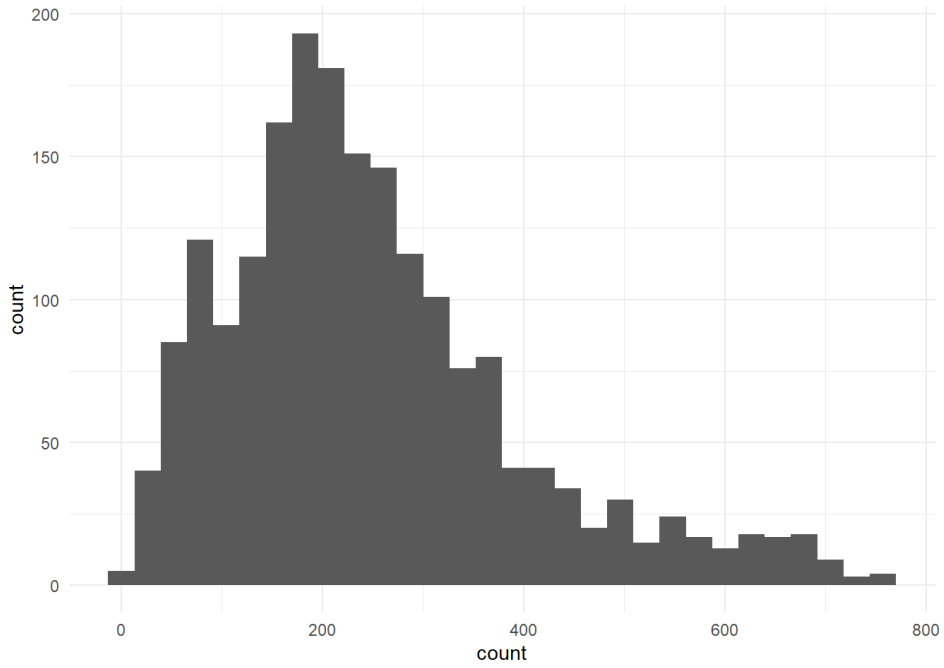


```r
# Dispersija didesnė už vidurkį
mean(train$count)

## [1] 251.3503
```

```
var(train$count)

## [1] 22014.63
```

Duomenų aibėje esanti mažiausia išnuomotų dviračių reikšmė yra lygi 12. Iš atsako kintamojo histogramos matoma, kad turimi duomenys su dešiniąja asimetrija. Apskaičiavus aprašomosios statistikos charakteristikas rasta, kad išnuomotų dviračių skaičiaus dispersija stipriai didesnė už vidurkį. Dėl šios priežasties daroma prielaida, kad Puasono regresijos modelis duomenims nebus tinkamas.

```
train %>%
  mutate(count = log(count)) %>%
  dplyr::select(c(temp, atemp, windspeed, humidity, count)) %>%
  pivot_longer(-count) %>%
  ggplot(aes(x = value, y = count, colour = name)) +
  geom_point() +
  geom_smooth(se = F, color = "red") +
  facet_wrap(~name, scales = "free") +
  theme_minimal()
```

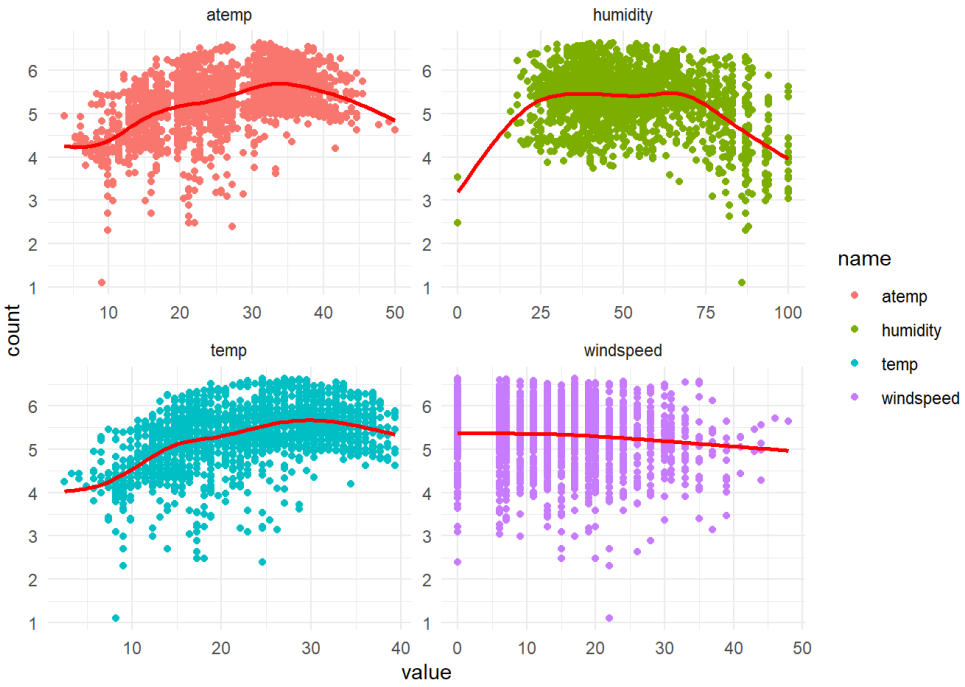


```
# Tarpusavio koreliacijos
library(corrplot)

correlation_matrix <- train %>%
  dplyr::select(where(is.numeric)) %>%
  cor()

corrplot(correlation_matrix, order = "original", method = "color", type = "upper", diag =
FALSE, tl.col = "black", addCoef.col = "black")
```

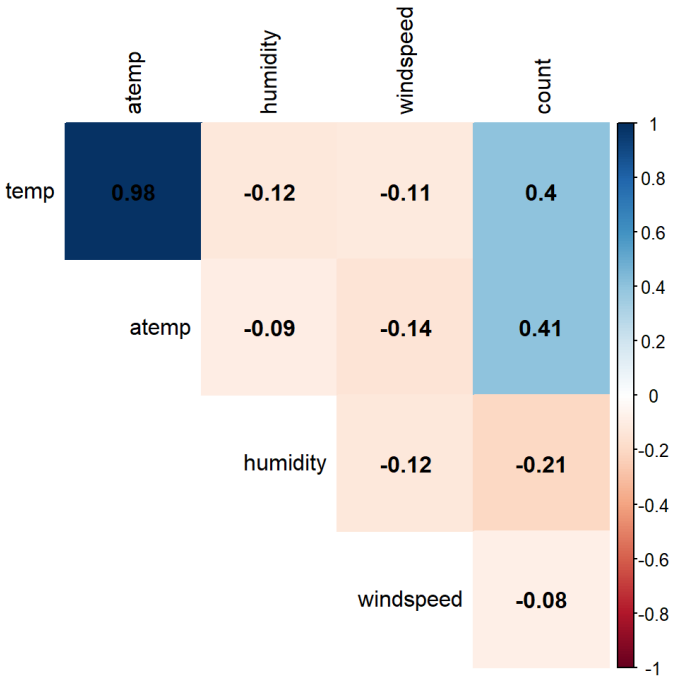

Rasti pakankamai tiesiniai ryšiai tarp skaitinių požymių ir išnuomotų dviračių skaičiaus logaritmo. Apskaičiavus koreliacijas tarp skaitinių duomenų aibės požymių rasta beveik visiškai tiesinis ryšys tarp oro temperatūros ir jutiminės oro temperatūros (r=0.98) . Dėl šios priežasties pasirinkta sudarant modelius kaip kovariantę įtraukti tik jutiminę oro temperatūrą.

```
train <- train %>% dplyr::select(-c(temp))

name <- full %>%
  dplyr::select(where(is.factor)) %>%
  names()

group <- function(x) {
  full %>%
    group_by(!!sym(x)) %>%
    summarize(mean = mean(count), var = var(count), n = n())
}

purrr::map(name, group)

## [[1]]
## # A tibble: 4 x 4
##   season  mean    var     n
##   <fct>  <dbl>  <dbl> <int>
## 1 1       152.  9830.   540
## 2 2       276. 22899.   552
## 3 3       293. 19199.   564
## 4 4       275. 21671.   530
##
## [[2]]
## # A tibble: 2 x 4
##   holiday  mean    var     n
```

```
##   <fct>   <dbl>  <dbl> <int>
## 1 0        248. 21573.  2123
## 2 1        291. 20152.    63
##
## [[3]]
## # A tibble: 2 x 4
##   workingday  mean    var     n
##   <fct>      <dbl>  <dbl> <int>
## 1 0           368. 30576.   693
## 2 1           194.  7851.  1493
##
## [[4]]
## # A tibble: 3 x 4
##   weather  mean    var     n
##   <fct>   <dbl>  <dbl> <int>
## 1 1        278. 22609.  1380
## 2 2        221. 14266.   632
## 3 3        125. 14994.   174
```

```
train %>%
  mutate(count = count) %>%
  dplyr::select(c(season, holiday, workingday, weather, count)) %>%
  pivot_longer(-count) %>%
  ggplot(aes(x = value, y = count, group = value)) +
  geom_boxplot() +
  facet_wrap(~name, scales = "free") +
  theme_minimal()
```

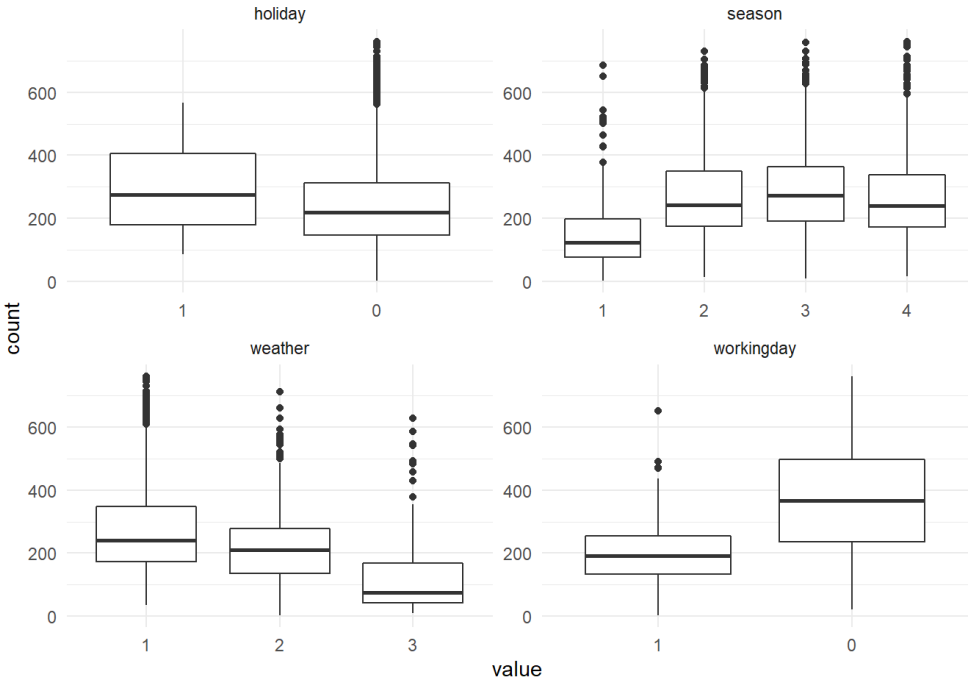

Apskaičiuotas išnuomotų dviračių skaičiaus vidurkis esant skirtingiems kategorinių kintamųjų lygmenims, pasiskirstymas pavaizduotas stačiakampėmis diagramomis.

```
# Puasono modelis
model_1 <- glm(count ~ ., family = "poisson", data = train)
summary(model_1)
```

```
##
## Call:
## glm(formula = count ~ ., family = "poisson", data = train)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -19.329   -4.418   -0.585    3.526   21.294
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept)  5.4093591  0.0085698  631.21  < 2e-16 ***
## season2      0.3525854  0.0056173   62.77  < 2e-16 ***
## season3      0.2529494  0.0067368   37.55  < 2e-16 ***
## season4      0.4679862  0.0049358   94.81  < 2e-16 ***
## holiday1    -0.2959043  0.0079517  -37.21  < 2e-16 ***
## workingday1 -0.6773281  0.0029401 -230.38  < 2e-16 ***
## weather2    -0.0152219  0.0037963   -4.01 6.08e-05 ***
## weather3    -0.4720235  0.0084025  -56.18  < 2e-16 ***
## atemp        0.0213013  0.0002731   78.00  < 2e-16 ***
## humidity    -0.0050001  0.0001071  -46.67  < 2e-16 ***
## windspeed   -0.0031659  0.0001686  -18.78  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for poisson family taken to be 1)
##
##     Null deviance: 164971  on 1966  degrees of freedom
## Residual deviance:  61911  on 1956  degrees of freedom
## AIC: 76041
##
## Number of Fisher Scoring iterations: 5

cat("Deviacija padalinta iš laisvės laipsnių: ", model_1$deviance / model_1$df.residual, "\n")

## Deviacija padalinta iš laisvės laipsnių:  31.6518

cat("Siekiama, kad būtų tarp 0.7 ir 1.3")

## Siekiama, kad būtų tarp 0.7 ir 1.3

# Tikrinima hipotezė, kad modelis nėra per didelės dispersijos (tiesinės dispersijos funkcijos
alternatyva)
dispersiontest(model_1, trafo = 1)

##
##  Overdispersion test
##
## data:  model_1
## z = 26.659, p-value < 2.2e-16
## alternative hypothesis: true alpha is greater than 0
## sample estimates:
##    alpha
## 30.50793
```

Sudarytas Puasono regresijos modelis, naudojantis visas duomenyse esančias kovariantes, ir įvertintas pasitelkiant nykščio taisyklę, teigiančią, kad deviacija, padalinta iš jos laisvės laipsnių turi priklausyti intervalui [0.7,1.3]. Gauta reikšmė nepatenka į šį intervalą.

Hipotezė, kad modelis nėra per didelės dispersijos esant tiesinės dispersijos funkcijos alternatyvai atmesta. Todėl sudarytas kvazi-Puasono modelis.

```r
model_2 <- glm(count ~ ., family = quasipoisson(), data = train)
summary(model_2)
```

```
##
## Call:
## glm(formula = count ~ ., family = quasipoisson(), data = train)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -19.329   -4.418   -0.585    3.526   21.294
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.4093591  0.0482365 112.142  < 2e-16 ***
## season2      0.3525854  0.0316178  11.151  < 2e-16 ***
## season3      0.2529494  0.0379188   6.671  3.3e-11 ***
## season4      0.4679862  0.0277817  16.845  < 2e-16 ***
## holiday1    -0.2959043  0.0447570  -6.611  4.9e-11 ***
## workingday1 -0.6773281  0.0165488 -40.929  < 2e-16 ***
## weather2    -0.0152219  0.0213681  -0.712 0.476325
## weather3    -0.4720235  0.0472948  -9.980  < 2e-16 ***
## atemp        0.0213013  0.0015372  13.857  < 2e-16 ***
## humidity    -0.0050001  0.0006030  -8.292  < 2e-16 ***
## windspeed   -0.0031659  0.0009489  -3.336 0.000865 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for quasipoisson family taken to be 31.68144)
##
##     Null deviance: 164971  on 1966  degrees of freedom
## Residual deviance:  61911  on 1956  degrees of freedom
## AIC: NA
##
## Number of Fisher Scoring iterations: 5
```

```r
plot(cooks.distance(model_2))
```

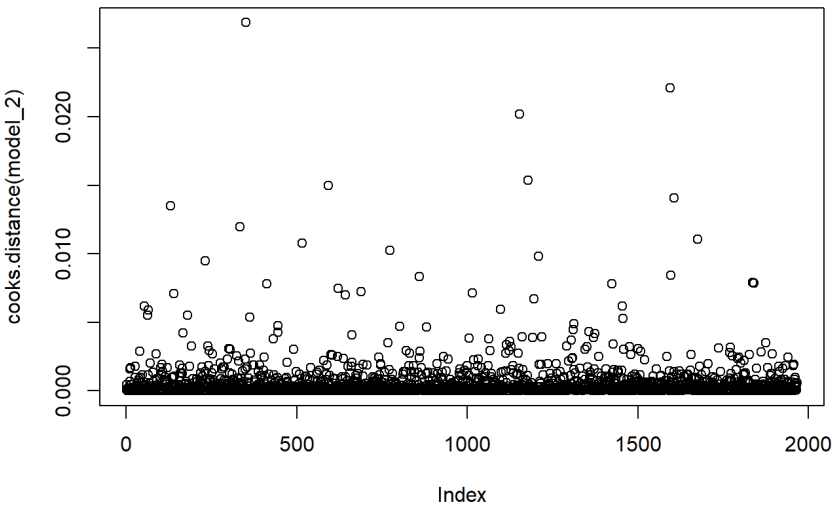

```
tibble(fitted = model_2$fitted.values,resid = resid(model_2, "pearson") / sqrt(31.8)) %>%
  ggplot(aes(fitted, resid)) +
  geom_point(alpha = 0.1) +
  geom_smooth(se = F)
```

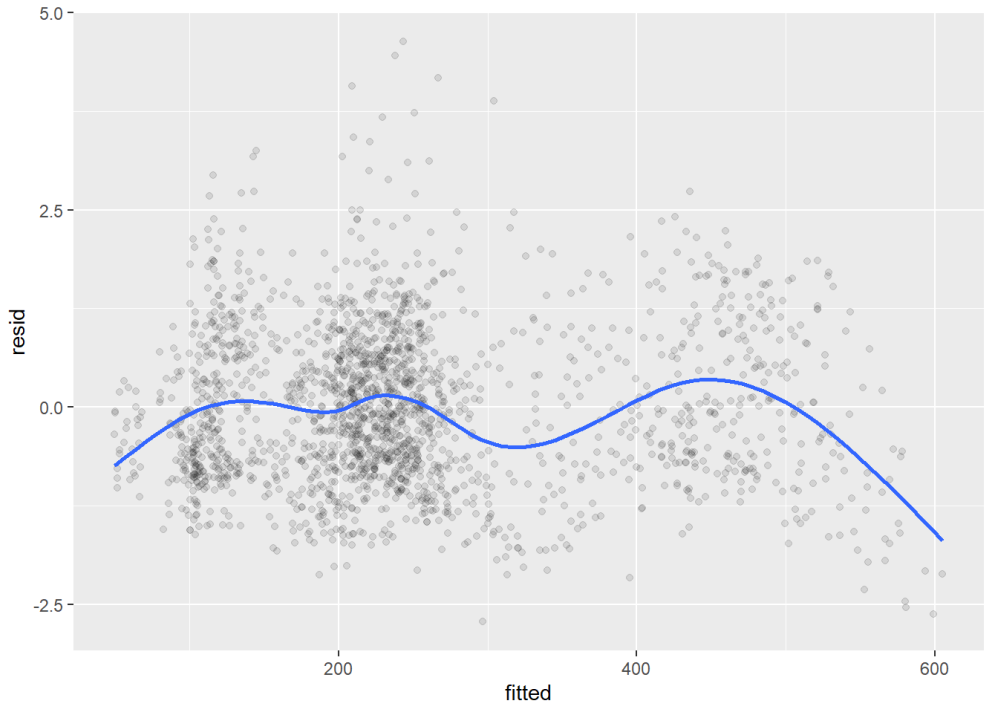


```
# Modelio koeficientų reikšmės
est <- cbind(Estimate = exp(coef(model_2)), exp(confint(model_2)))
est
```

```
##                 Estimate       2.5 %      97.5 %
## (Intercept) 223.4883055 203.2891364 245.6024019
## season2       1.4227412   1.3373440   1.5138075
## season3       1.2878182   1.1956824   1.3872969
## season4       1.5967753   1.5122960   1.6862980
## holiday1      0.7438586   0.6806378   0.8111957
## workingday1   0.5079724   0.4917668   0.5247259
## weather2      0.9848934   0.9444102   1.0269243
## weather3      0.6237388   0.5680586   0.6837840
## atemp         1.0215298   1.0184580   1.0246135
## humidity      0.9950124   0.9938362   0.9961880
## windspeed     0.9968391   0.9949859   0.9986938
```

```
library(effects)
plot(predictorEffects(model_2))
```

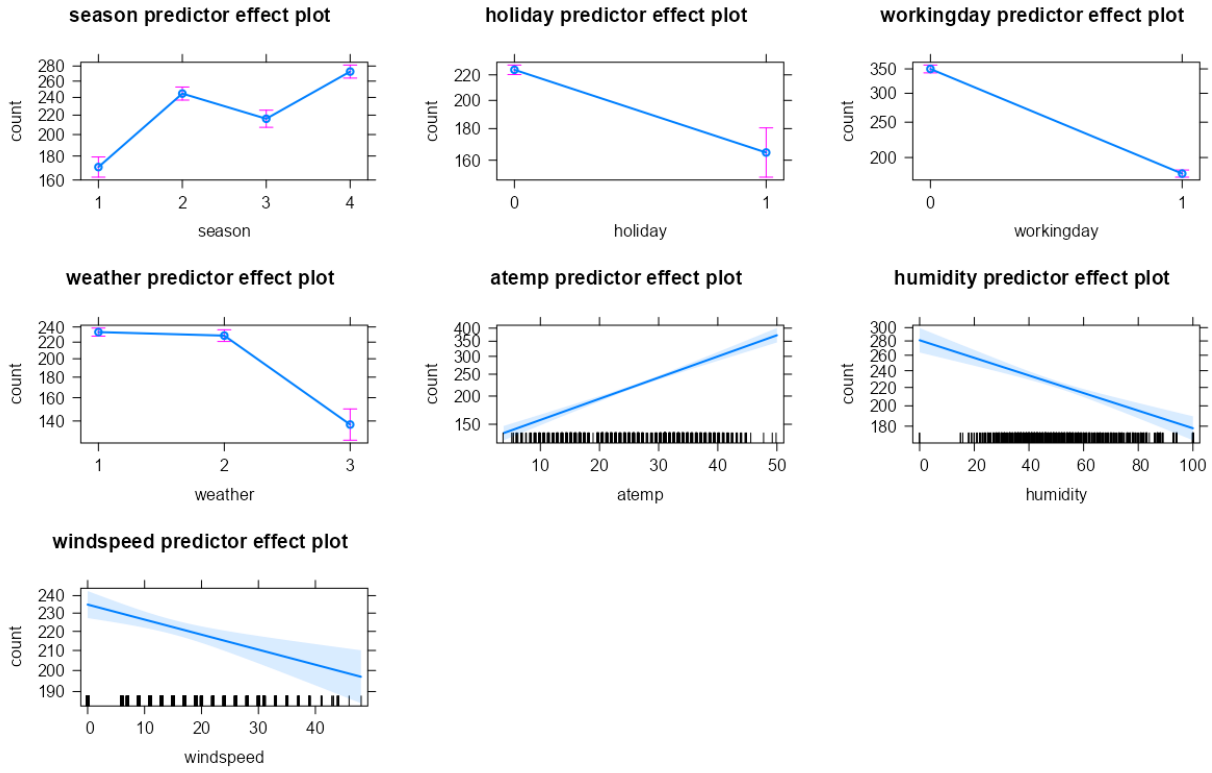

Gautame modelyje visos kovariantės reikšmingos.

Modelio koeficientų interpretacija įprasta modeliams, naudojantiems logaritminę jungties funkciją: koeficientų reikšmės atitinka kiekybinį atsako vidurkio logaritmo pokytį tą koeficientą atitinkančiai kovariantei pakitus vienetu, o likusioms kovariantėms esant fiksuotoms. Eksponencijuojant šiuos koeficientus gaunama kiek kartų padidėja atsako vidurkis.

Modelio gauti koeficientai panaudoti interpretuoti duomenyse esančių kovariačių ir atsako ryšį: Šventinėmis dienomis išnuomojama 26% mažiau dviračių negu įprastomis. Darbo dienomis išnuomojamų dviračių skaičius 50% procentų mažesnis negu nedarbo dienomis. Didėjant temperatūrai ir mažėjant oro drėgnumui išnuomojama daugiau dviračių. Didesnis vėjo greitis neigiamai veikia išnuomojamų dviračių skaičių.

```
# Modelio panaudojimas prognozėms naudojant testavimo duomenų aibę
test_with_pred <- test %>% mutate(count = count, pred = predict(model_2, test, type =
"response"))

test_with_pred %>%
  dplyr::select(c(count, pred)) %>%
  pivot_longer(everything()) %>%
  ggplot(aes(x = value, fill = name)) +
  geom_histogram(bins = 12) +
  theme_minimal() +
  facet_wrap(vars(name))
```

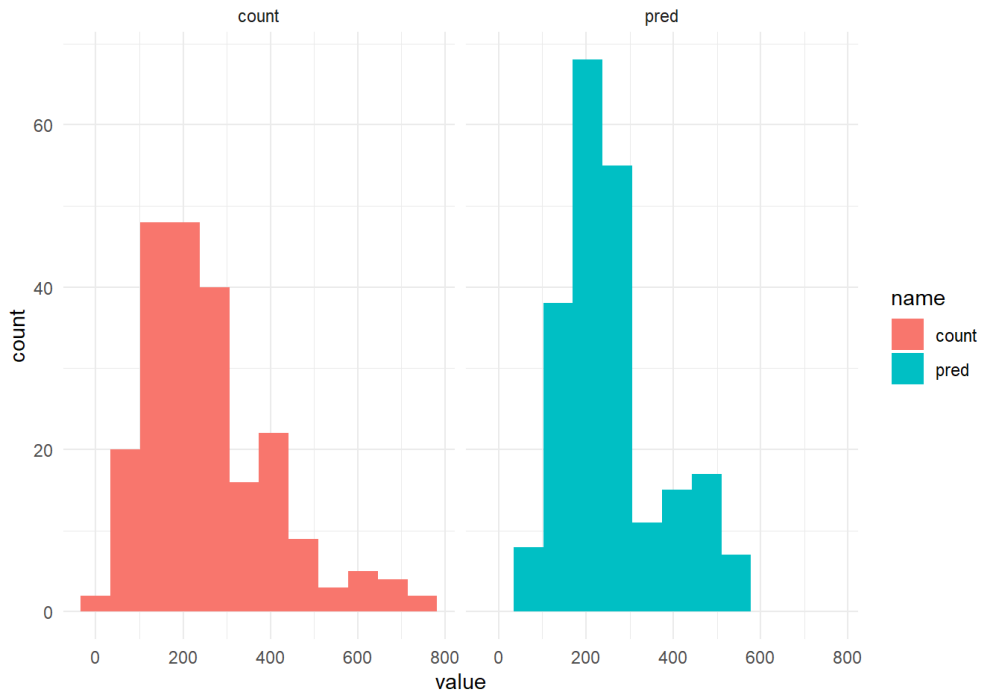


```
library(yardstick)

rmse(test_with_pred, count, pred)

## # A tibble: 1 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 rmse    standard        91.0

mae(test_with_pred, count, pred)

## # A tibble: 1 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 mae     standard        73.2
```

Modelis panaudotas atlikti prognozes naudojant testavimo aibės duomenis (RMSE=91, MAE=73). Iš prognozuotų ir stebėtų reikšmių histogramos pastebima, kad gautas modelis nelinkęs prognozuoti ekstremalias reikšmes, esančias testavimo aibėje. Laikant, kad būtent tokių reikšmių prognozavimas gali būti svarbiausias, modelio negalima laikyti tinkamu prognozuoti dviračių nuomos paklausą.

Hipotezė, kad modelis nėra per didelės dispersijos esant kvadratinės dispersijos funkcijos alternatyvai taip pat atmesta, todėl kaip alternatyva sudarytas neigiamo binominio skirstinio regresijos modelis.

```r
# Palyginimui sudaromas neigiamas binominis modelis (kvadratinė dispersijos funkcija)
dispersiontest(model_1, trafo = 2)
```

```
##
##  Overdispersion test
##
## data:  model_1
## z = 25.533, p-value < 2.2e-16
## alternative hypothesis: true alpha is greater than 0
## sample estimates:
##     alpha
## 0.1064244
```

```r
model_3 <- glm.nb(count  ~ ., data = train)
summary(model_3)
```

```
##
## Call:
## glm.nb(formula = count ~ ., data = train, init.theta = 6.754799939,
##     link = log)
##
## Deviance Residuals:
##     Min       1Q   Median       3Q      Max
## -4.7468  -0.7857  -0.1109   0.5737   3.1238
##
## Coefficients:
##               Estimate Std. Error z value Pr(>|z|)
## (Intercept)  5.3435252  0.0509210 104.938  < 2e-16 ***
## season2      0.3113537  0.0315978   9.854  < 2e-16 ***
## season3      0.2065184  0.0391877   5.270 1.36e-07 ***
## season4      0.4420221  0.0277014  15.957  < 2e-16 ***
## holiday1    -0.2916371  0.0534122  -5.460 4.76e-08 ***
## workingday1 -0.6702809  0.0196329 -34.141  < 2e-16 ***
## weather2     0.0001540  0.0228405   0.007  0.99462
## weather3    -0.5215176  0.0420013 -12.417  < 2e-16 ***
## atemp        0.0259243  0.0016459  15.751  < 2e-16 ***
## humidity    -0.0057120  0.0006397  -8.929  < 2e-16 ***
## windspeed   -0.0031533  0.0010323  -3.055  0.00225 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for Negative Binomial(6.7548) family taken to be 1)
##
##     Null deviance: 4933.9  on 1966  degrees of freedom
## Residual deviance: 2038.1  on 1956  degrees of freedom
## AIC: 23032
##
## Number of Fisher Scoring iterations: 1
##
##
##               Theta:  6.755
##           Std. Err.:  0.221
##
##  2 x log-likelihood:  -23007.668
```

```r
cat("Deviacija padalinta iš laisvės laipsnių: ", model_3$deviance / model_3$df.residual, "\n")
```

```
## Deviacija padalinta iš laisvės laipsnių:  1.041966
```

```
plot(cooks.distance(model_3))
```

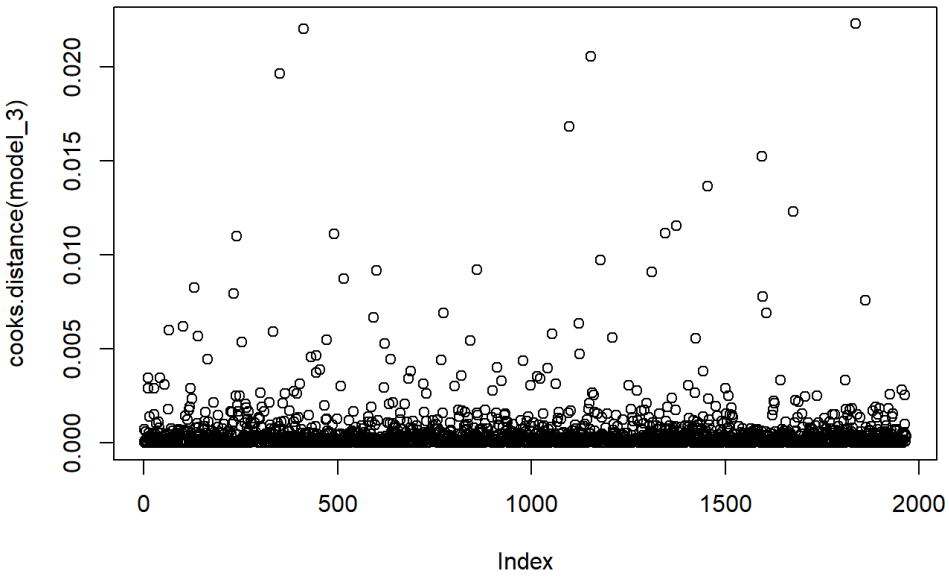


```
tibble(fitted = model_2$fitted.values,resid = resid(model_3, "pearson")) %>%
  ggplot(aes(fitted, resid)) +
  geom_point(alpha = 0.1) +
  geom_smooth(se = F)
```

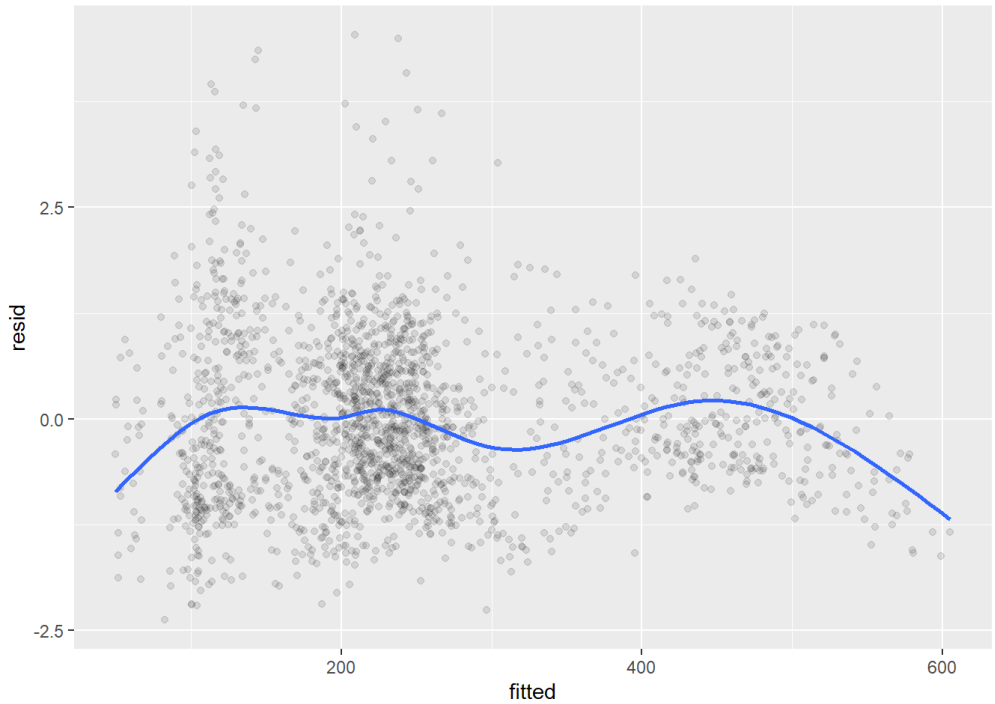

```r
# Galima pažingsninė regresija
model_3_step <- stepAIC(model_3)

## Start:  AIC=23029.67
## count ~ season + holiday + workingday + weather + atemp + humidity +
##     windspeed
##
##              Df   AIC
## <none>          23030
## - windspeed   1 23037
## - holiday     1 23055
## - humidity    1 23102
## - weather     2 23194
## - atemp       1 23255
## - season      3 23309
## - workingday  1 24000

# Gaunamas lygiai toks pat modelis
anova(model_3, model_3_step)

## Likelihood ratio tests of Negative Binomial Models
##
## Response: count
##                                                                      Model  theta
## 1 season + holiday + workingday + weather + atemp + humidity + windspeed 6.7548
## 2 season + holiday + workingday + weather + atemp + humidity + windspeed 6.7548
##   Resid. df    2 x log-lik.   Test    df LR stat. Pr(Chi)
## 1      1956       -23007.67
## 2      1956       -23007.67 1 vs 2     0        0       1

est <- cbind(Estimate = exp(coef(model_3)), exp(confint(model_3)))
est

##                Estimate       2.5 %      97.5 %
## (Intercept) 209.2490618 188.7297456 232.0759517
## season2       1.3652720   1.2849954   1.4505574
## season3       1.2293903   1.1418605   1.3235689
## season4       1.5558501   1.4749961   1.6411527
## holiday1      0.7470396   0.6737462   0.8306305
## workingday1   0.5115648   0.4922404   0.5315539
## weather2      1.0001540   0.9566608   1.0457851
## weather3      0.5936190   0.5478114   0.6437314
## atemp         1.0262633   1.0229109   1.0296238
## humidity      0.9943043   0.9930314   0.9955812
## windspeed     0.9968517   0.9948164   0.9988934

plot(predictorEffects(model_3))
```

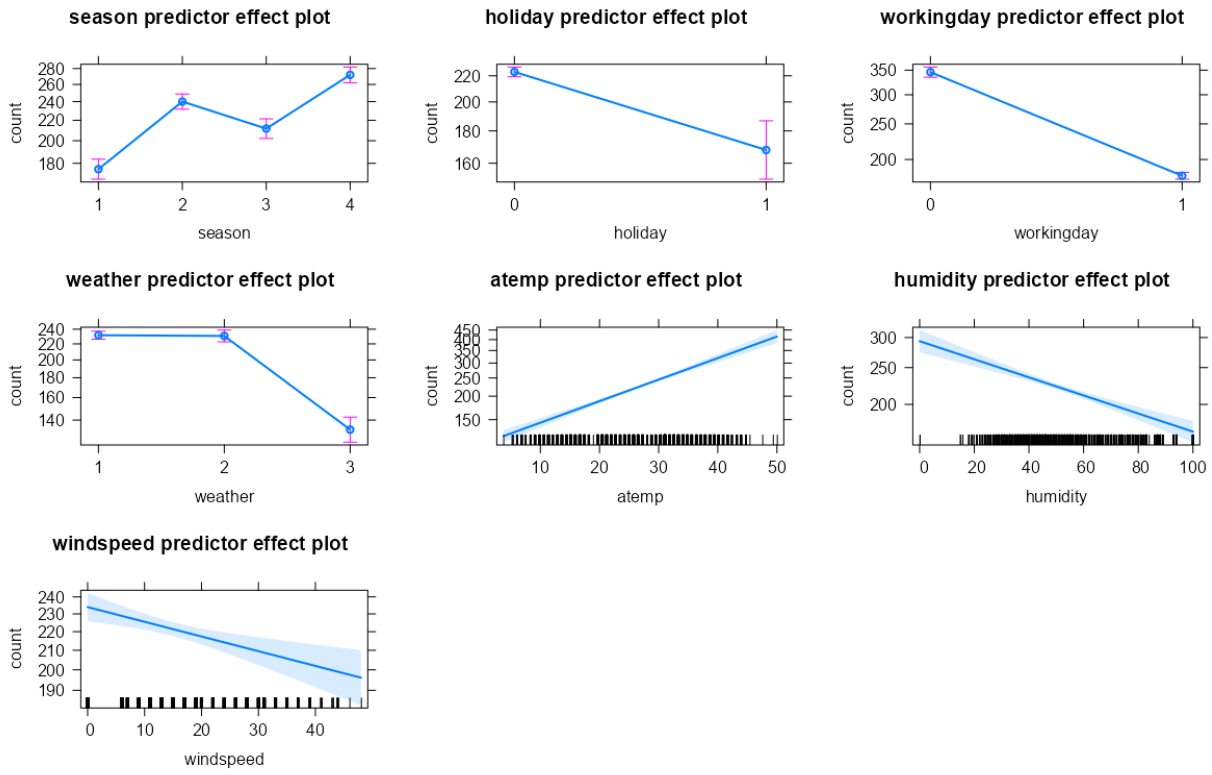

Priešingai negu kvazi-Puasono modelis, neigiamo binominio modelis leidžia naudoti su tikėtinumu susijusius kriterijus. Pasitelkiant ankščiau aprašytą nykščio taisyklę gauta reikšmė – 1.04. Naudojant pažingsninę regresiją pagal AIC iš modelio nepašalinta jokia kovariantė.

Gauti modelio koeficientai tik minimaliai skiriasi nuo prieš tai gauto Puasono modelio.

```
test_with_pred <- test %>% mutate(count = count, pred = predict(model_3, test, type =
"response"))

test_with_pred %>%
  dplyr::select(c(count, pred)) %>%
  pivot_longer(everything()) %>%
  ggplot(aes(x = value, fill = name)) +
  geom_histogram(bins = 12) +
  theme_minimal() +
  facet_wrap(vars(name))
```

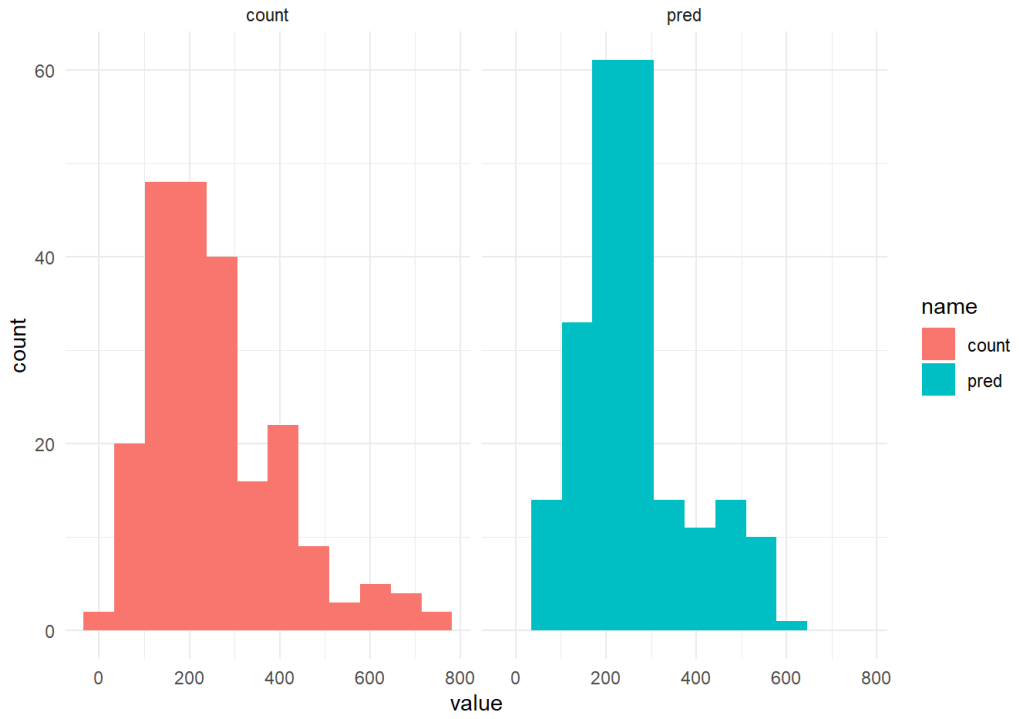


```
library(yardstick)

rmse(test_with_pred, count, pred)

## # A tibble: 1 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 rmse    standard        92.3

mae(test_with_pred, count, pred)

## # A tibble: 1 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>          <dbl>
## 1 mae     standard        73.4
```

Prognozuojant testavimo aibėje esančias reikšmes gaunami minimaliai prastesni rezultatai lyginant su kvazi-Puasono modeliu (RMSE=92, MAE=73).

Išvados:

Duomenų aibė sumažinta iki stebėjimų gautų nuo 12 iki 14 valandos ir pasirinkta sudaryti regresijos modelį išnuomotų dviračių skaičiui esant šioms valandoms.

Laikyta, kad Puasono regresijos modelis yra netinkamas dėl per didelės atsako dispersijos palyginus su vidurkiu. Hipotezė, kad modelis nėra per didelės dispersijos esant tiesinės dispersijos funkcijos alternatyvai atmesta, todėl sudarytas kvazi-Puasono modelis naudojantis visas duomenyse esančias kovariantės. Sudarytame modelyje nereikšmingų kovariančių nerasta.

Modelis panaudotas siekiant interpretuoti duomenyse esančių kovariančių ir atsako sąryšį: Kitoms kovariantėms esant pastovioms, šventinėmis dienomis ir darbo dienomis išnuomojama atitinkamai 26% ir 50% mažiau dviračių. Didesnė oro temperatūra teigiamai įtakoja dviračių nuomos paklausą, oro drėgnumas ir vėjo greitis – neigiamai.

Naudojant modelį prognozuoti išnuomotų dviračių skaičių testavimo aibėje rasta, kad modelis prastai prognozuoja ekstremalias išnuomotų dviračių skaičiaus reikšmes. Laikant, kad būtent tokių reikšmių prognozavimas gali būti svarbiausias, modelio negalima laikyti tinkamu prognozuoti dviračių nuomos paklausą.

Palyginimui sudarytas ir neigiamo binominio skirstinio modelis išnuomotų dviračių skaičiui. Gautame modelyje visos duomenyse esančios kovariantės taip pat reikšmingos. Modelis panaudotas prognozuoti išnuomotų dviračių skaičių testavimo aibėje tačiau geresni rezultatai, palyginus su Puasono modeliu, negauti.

2. Naudojant Python

Atlikta analizė pakartotinai atlikta naudojant Python.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm
import seaborn as sns

test = pd.read_csv("test_from_R.csv")
train = pd.read_csv("train_from_R.csv")

train['season'] = train.season.astype('category')
train['holiday'] = train.holiday.astype('category')
train['workingday'] = train.workingday.astype('category')
train['weather'] = train.weather.astype('category')



test['season'] = test.season.astype('category')
test['holiday'] = test.holiday.astype('category')
test['workingday'] = test.workingday.astype('category')
test['weather'] = test.weather.astype('category')

train
```

	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	count
0	2	0	1	2	14.76	18.180	87.0	7.0015	84
1	4	0	1	1	20.50	24.240	51.0	12.9980	179
2	2	0	1	2	24.60	31.060	38.0	0.0000	217
3	3	0	1	1	30.34	32.575	35.0	7.0015	229
4	1	0	1	2	8.20	9.090	40.0	19.0012	54
...	...	...	...	...	...	...	...	...	...
1962	1	0	1	1	16.40	20.455	43.0	11.0014	234
1963	1	0	1	3	9.02	9.850	87.0	22.0028	10
1964	2	0	1	1	20.50	24.240	51.0	26.0027	107
1965	3	0	1	1	33.62	37.120	43.0	7.0015	203

	season	holiday	workingday	weather	temp	atemp	humidity	windspeed	count
1966	2	0	1	1	31.16	33.335	31.0	26.0027	373

1967 rows × 9 columns

```
sns.set_context("notebook")
sns.displot(x="count",data=train,kind="hist",bins=15)
```

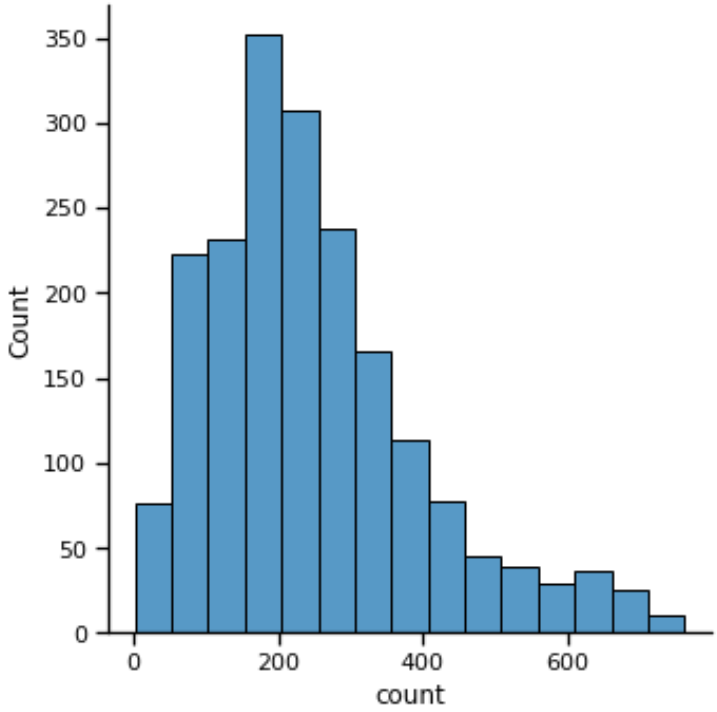


```
df_numeric = train[["temp","atemp","humidity","windspeed","count"]]
corr = df_numeric.corr()
mask = np.triu(np.ones_like(corr, dtype=bool))

f, ax = plt.subplots(figsize=(10,8))
cmap = sns.diverging_palette(15,240,as_cmap=True)
plot=sns.heatmap(corr,mask=mask,vmax=1,vmin=-
1,center=0,cmap=cmap,square=True,cbar_kws={"shrink":.5},
            linewidth=1,ax=ax,annot=True)
plot.tick_params(axis='x', rotation=45)
```

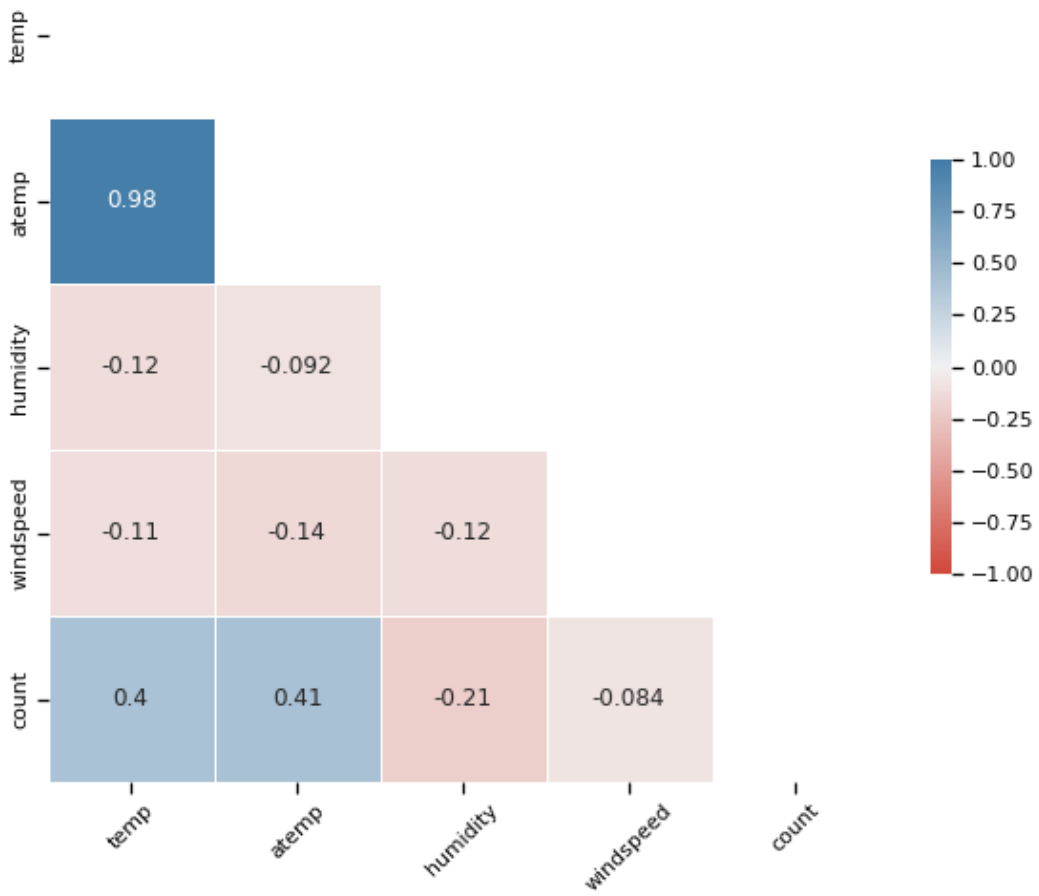


```
df_numeric = train[["temp","atemp","humidity","windspeed","count"]]
df_numeric["count"] = np.log(df_numeric["count"])
df_long = df_numeric.melt("count")

sns.relplot(x="value",y="count",data=df_long,col="variable",hue="variable",
            alpha=0.4,kind="scatter",col_wrap=3,facet_kws={'sharex': False})
```

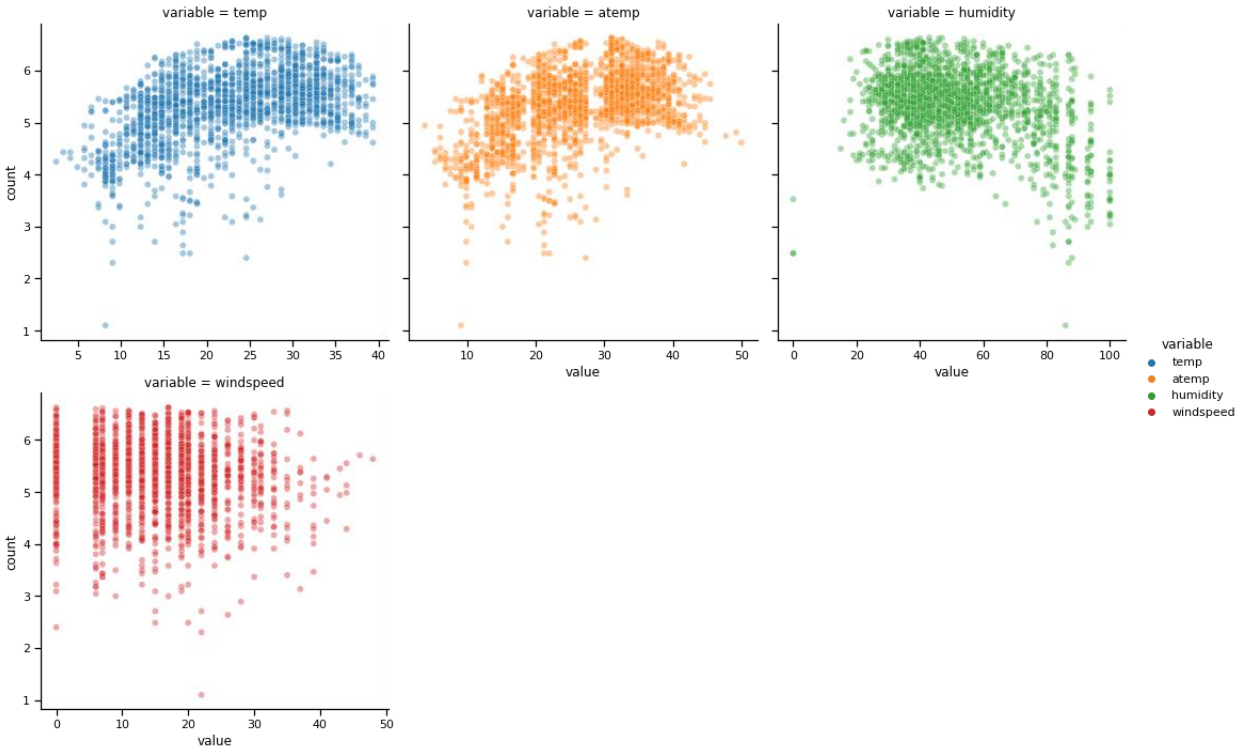


```
train = train.drop("temp",axis=1)
test = test.drop("temp",axis=1)
df_categorical = train[["season","holiday","workingday","weather","count"]]
df_categorical["count"] = df_categorical["count"]
df_long = df_categorical.melt("count")

sns.catplot(x="value",y="count",data=df_long,col="variable",kind="box",col_wrap=3,sharey=False
,sharex=False)
```

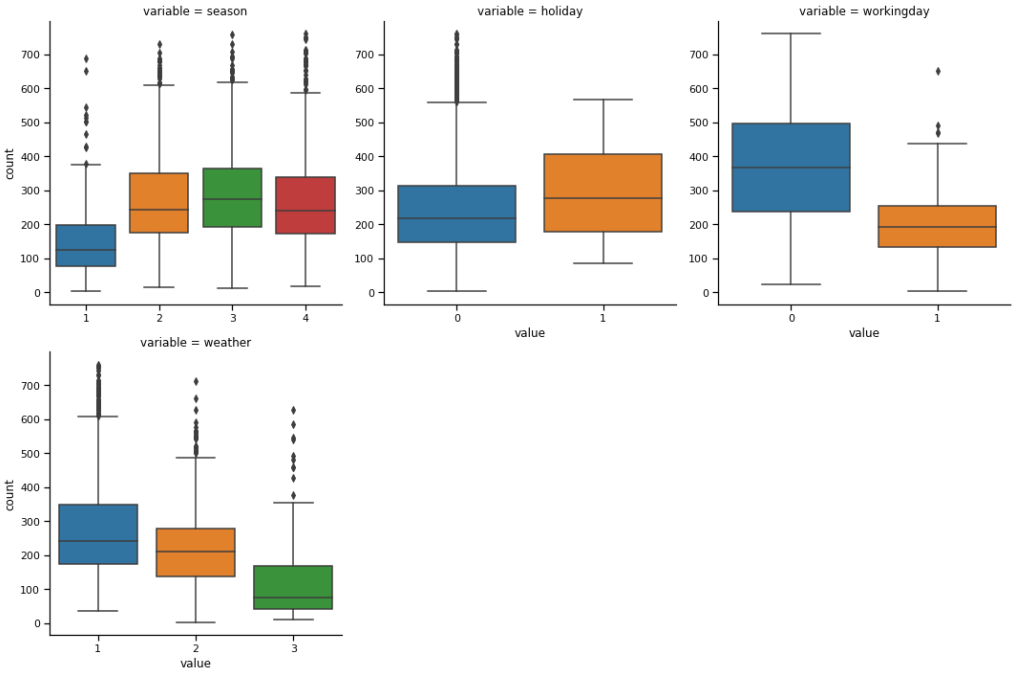


```
import patsy

y, X = patsy.dmatrices('count ~ season + holiday + workingday + weather + atemp + humidity +
windspeed',
                       data=train, return_type='dataframe')

y_test, X_test = patsy.dmatrices('count ~ season + holiday + workingday + weather + atemp +
humidity + windspeed',
                       data=test, return_type='dataframe')
```

Poisson model

```
model_1=sm.GLM(y,X,family=sm.families.Poisson())
res_1=model_1.fit()
dispersion = res_1.deviance / res_1.df_resid
print(dispersion)
31.699540558317672
model_2=sm.GLM(y,X,family=sm.families.Poisson(),var_weights=np.repeat(1/dispersion,len(y)))
res_2=model_2.fit()
res_2.summary()
```

Generalized Linear Model Regression Results

Dep. Variable:	count	**No. Observations:**	1967
Model:	GLM	**Df Residuals:**	1956
Model Family:	Poisson	**Df Model:**	10

Link Function:	log	**Scale:**	1.0000
Method:	IRLS	**Log-Likelihood:**	-1200.1
Date:	Sun, 27 Mar 2022	**Deviance:**	1956.0
Time:	22:58:57	**Pearson chi2:**	1.96e+03
No. Iterations:	5		
Covariance Type:	nonrobust		

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	5.3583	0.049	108.821	0.000	5.262	5.455
season[T.2]	0.3683	0.032	11.438	0.000	0.305	0.431
season[T.3]	0.2615	0.039	6.756	0.000	0.186	0.337
season[T.4]	0.4749	0.028	16.669	0.000	0.419	0.531
holiday[T.1]	-0.2884	0.045	-6.345	0.000	-0.377	-0.199
workingday[T.1]	-0.6747	0.017	-40.431	0.000	-0.707	-0.642
weather[T.2]	-0.0036	0.021	-0.171	0.864	-0.045	0.038
weather[T.3]	-0.4894	0.046	-10.652	0.000	-0.580	-0.399
atemp	0.0217	0.002	13.938	0.000	0.019	0.025
humidity	-0.0046	0.001	-7.584	0.000	-0.006	-0.003
windspeed	-0.0031	0.001	-3.198	0.001	-0.005	-0.001

```
fig, ax = plt.subplots(1,1,figsize=(10, 8))
ax =
sns.regplot(res_2.mu,res_2.resid_pearson,ax=ax,scatter_kws={"alpha":0.3},line_kws={"color":"re
d"},lowess=True)
ax.set_xlabel("Fitted values")
ax.set_ylabel("Pearson residuals")
```

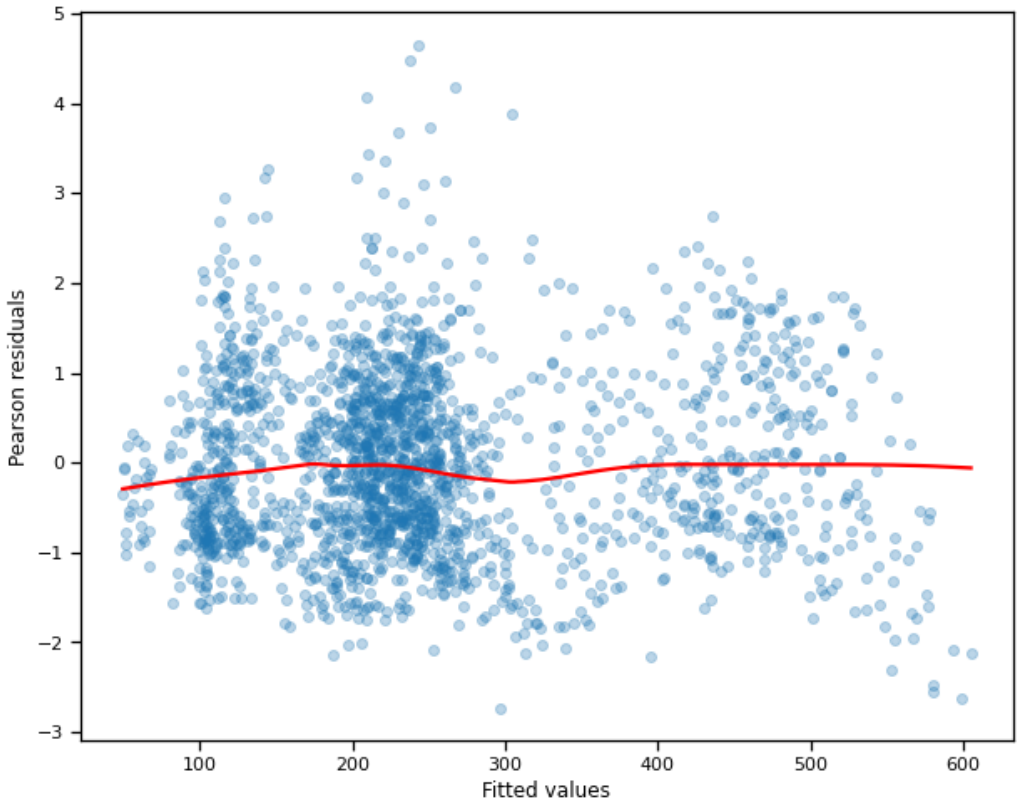


```
np.exp(res_2.params)
```

```
Intercept         212.358282
season[T.2]         1.445307
season[T.3]         1.298817
season[T.4]         1.607846
holiday[T.1]        0.749467
workingday[T.1]     0.509287
weather[T.2]        0.996372
weather[T.3]        0.612968
atemp               1.021897
humidity            0.995417
windspeed           0.996951
dtype: float64
```

```
results = pd.DataFrame({"observed":test["count"],"pred":res_2.predict(X_test)})
ax = sns.displot(x="value",col="variable",hue="variable",data=results.melt(),bins=12)
ax.fig.subplots_adjust(top=0.85)
ax.fig.suptitle("Negative binomial model")
```

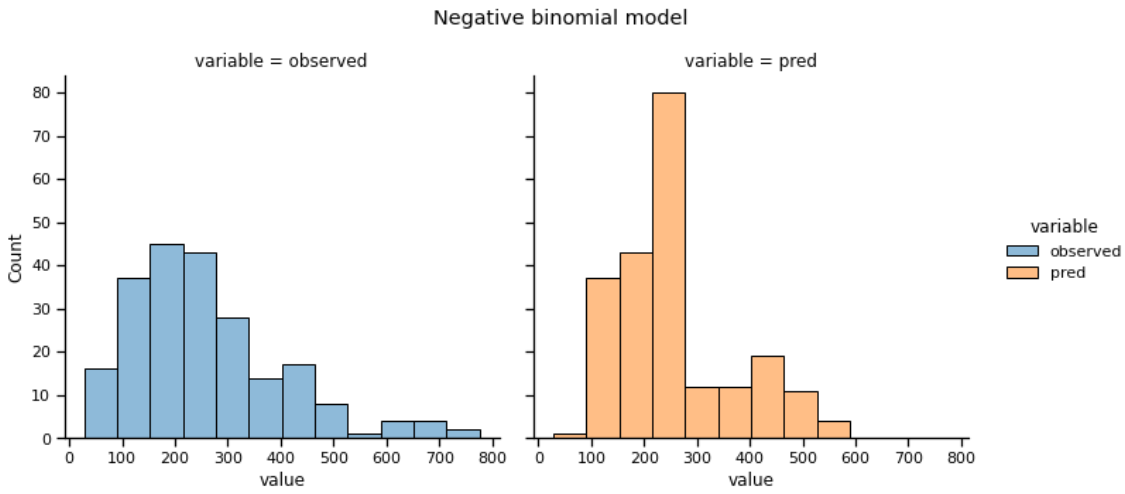


```
from sklearn.metrics import mean_squared_error, mean_absolute_error

print("RMSE:",np.sqrt(mean_squared_error(results["observed"],results["pred"])))

print("MAE:",mean_absolute_error(results["observed"],results["pred"]))
```

RMSE: 96.193835771219
MAE: 74.04321903936005

Negative binomial

```
model_3=sm.GLM(y,X,family=sm.families.NegativeBinomial(alpha=1/6.64))
res_3=model_3.fit()
res_3.summary()
```

Generalized Linear Model Regression Results

Dep. Variable:	count	**No. Observations:**	1967
Model:	GLM	**Df Residuals:**	1956
Model Family:	NegativeBinomial	**Df Model:**	10
Link Function:	log	**Scale:**	1.0000
Method:	IRLS	**Log-Likelihood:**	-11492.
Date:	Sun, 27 Mar 2022	**Deviance:**	2035.6
Time:	22:58:59	**Pearson chi2:**	1.91e+03
No. Iterations:	8		

Covariance Type: nonrobust

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	5.2858	0.052	102.262	0.000	5.185	5.387
season[T.2]	0.3266	0.032	10.238	0.000	0.264	0.389
season[T.3]	0.2172	0.040	5.466	0.000	0.139	0.295
season[T.4]	0.4465	0.028	15.885	0.000	0.391	0.502
holiday[T.1]	-0.2751	0.055	-4.982	0.000	-0.383	-0.167
workingday[T.1]	-0.6668	0.020	-33.336	0.000	-0.706	-0.628
weather[T.2]	0.0102	0.023	0.443	0.658	-0.035	0.055
weather[T.3]	-0.5419	0.041	-13.209	0.000	-0.622	-0.461
atemp	0.0264	0.002	15.887	0.000	0.023	0.030
humidity	-0.0053	0.001	-8.205	0.000	-0.007	-0.004
windspeed	-0.0030	0.001	-2.865	0.004	-0.005	-0.001

```
fig, ax = plt.subplots(1,1,figsize=(10, 8))
ax =
sns.regplot(res_3.mu,res_3.resid_pearson,ax=ax,scatter_kws={"alpha":0.3},line_kws={"color":"re
d"},lowess=True)
ax.set_xlabel("Fitted values")
ax.set_ylabel("Pearson residuals")
```

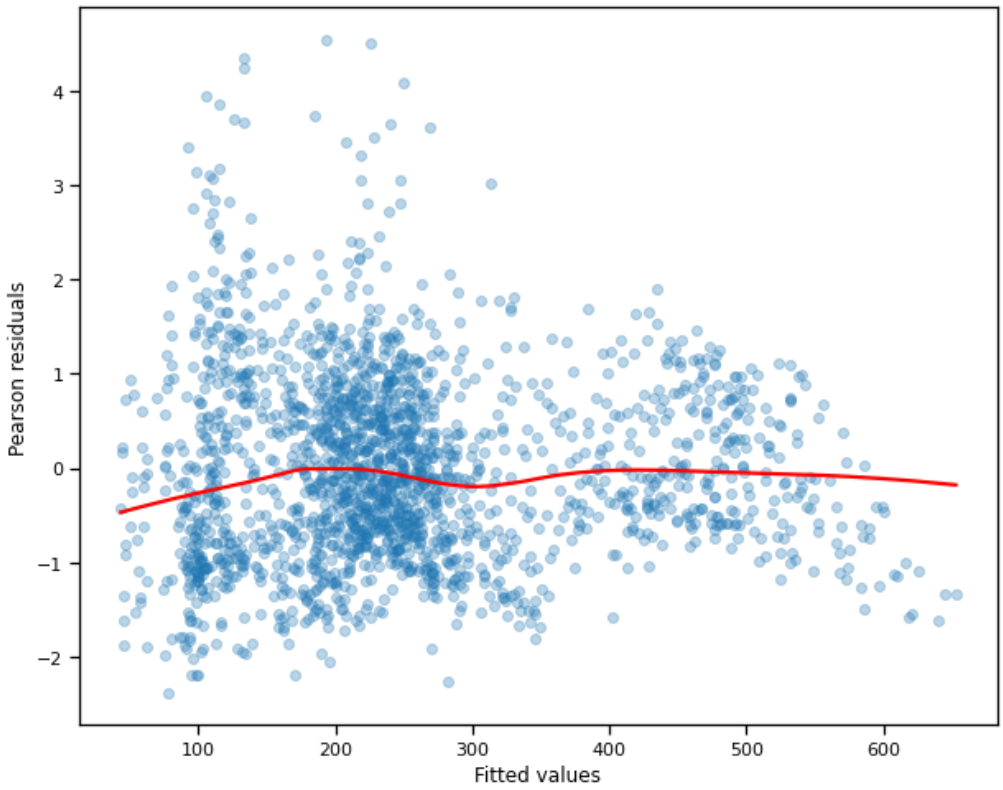


```
np.exp(res_3.params)
```

```
Intercept         197.516616
season[T.2]         1.386241
season[T.3]         1.242618
season[T.4]         1.562877
holiday[T.1]        0.759489
workingday[T.1]     0.513364
weather[T.2]        1.010218
weather[T.3]        0.581659
atemp               1.026768
humidity            0.994749
windspeed           0.997020
dtype: float64
```

```
results = pd.DataFrame({"observed":test["count"],"pred":res_3.predict(X_test)})
ax = sns.displot(x="value",col="variable",hue="variable",data=results.melt(),bins=12)
ax.fig.subplots_adjust(top=0.85)
ax.fig.suptitle("Negative binomial model")
```

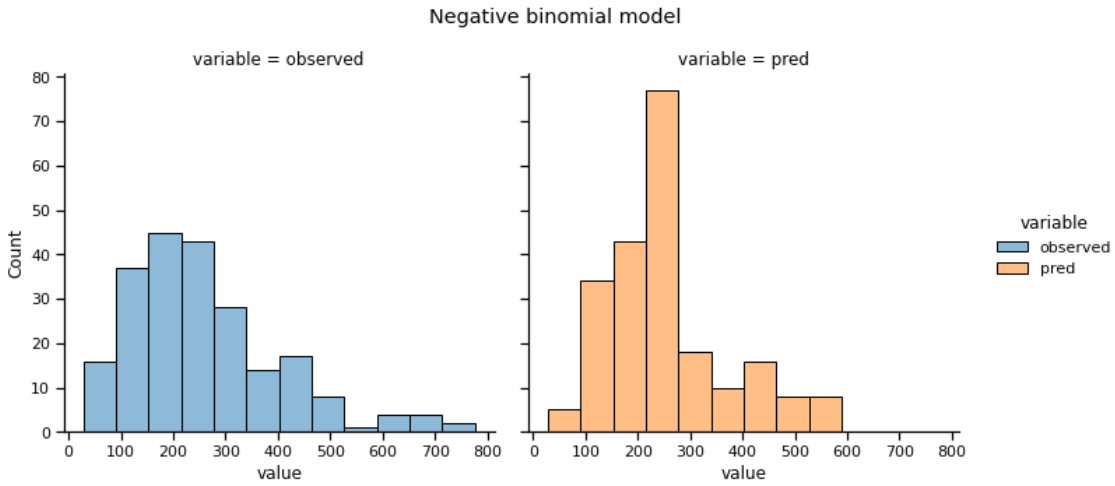


```
from sklearn.metrics import mean_squared_error, mean_absolute_error

print("RMSE:",np.sqrt(mean_squared_error(results["observed"],results["pred"])))

print("MAE:",mean_absolute_error(results["observed"],results["pred"]))
```

RMSE: 96.86917306613684
MAE: 74.94004248627321