



Vilniaus Universitetas

Netiesinė regresija

Laboratorinis darbas

Darbą atliko:

Vainius Gataveckas, Matas Gaulia, Dovydas Martinkus

Duomenų Mokslas

3 kursas 2 gr.

Vilnius, 2022

Turiny

Naudoti metodai	3
Duomenys ir jų šaltiniai.....	4
Tikslas ir uždaviniai	5
Atliktos analizės aprašymas	6
1. Naudojant R	6

Naudoti metodai

Šiame darbe naudotas apibendrintas adityvus modelis su glodniaisiais splineais. Darbas atliktas naudojant R.

Naudoti R paketai:

tidyverse

rsample

corrplot

car

mgcv

gratia

effect

Duomenys ir jų šaltiniai

Betono mišinio stiprio duomenys pagal betono mišinį sudarančias medžiagas.

Duomenų šaltinis – UCI Machine Learning Repository. Prieiga per internetą:

<https://archive.ics.uci.edu/ml/datasets/concrete+compressive+strength>.

„cement“ - Cemento kiekis (kg viename m^3 mišinio).

„blast_furnace_slag“ - aukštakrosnių šlako (kg viename m^3 mišinio).

„fly_ash“ - Lakiųjų pelenų kiekis (kg viename m^3 mišinio).

„water“ - Vandens kiekis (kg viename m^3 mišinio).

„superplasticizer“ - Superplastiklių kiekis (kg viename m^3 mišinio).

„coarse_aggregate“ - stambiojo užpildo kiekis betono mišinyje (kg viename m^3 mišinio).

„fine_aggregate“ - smulkiojo (smėlio) užpildo kiekis betono mišinyje (kg viename m^3 mišinio).

„age“ - Amžius (dienomis).

„strength“ - Cemento stipris gniaužiant (viekiant kompresinė spauda) (MPa) (atsako kintamasis).

Tikslas ir uždaviniai

Tikslas: Sudaryti netiesinį regresijos modelį betono stipriui prognozuoti pagal jo sudėties mišinį, kuris reikšmes prognozuotų tiksliau už tiesinį regresijos modelį.

Uždaviniai:

Tiesinio regresijos modelio betono stipriui sudarymas.

Tinkamų netiesinės regresijos metodų pasirinkimas turimai duomenų aibei.

Netiesinio regresijos modelio sudarymas.

Modelių tinkamumo analizė.

Modelių palyginimas, panaudojimas prognozuoti betono stiprį esant tam tikrai mišinio sudėčiai.

Atliktos analizės aprašymas

1. Naudojant R

Duomenų aibę apskritai sudaro 1030 stebėjų, tačiau 25 iš jų yra pasikartojantys (pagal visus požymius). Laikyta, kad šitie pasikartojantys stebėjimai neturėtų įtakoti modeliuojamo sąryšio tarp kovariančių ir atsako kintamojo, todėl pasirinkta šiuos stebėjimus pašalinti. Duomenų aibėje nėra praleistų reikšmių. Duomenys padalinti į mokymo ir testavimo aibes naudojant 75-25 santykį.

Nagrinėjant Pirsono koreliacijas tarp betono stiprio ir kovariančių vidutinė arba stipri koreliacija rasta tik su maža dalimi požymių. Kadangi Pirsono koreliacija matuoja tik tiesinį sąryšį tarp kintamųjų, iš prieš tai gauto rezultato pasirinkta laikyti, kad betono stipris gali būti ir netiesinė savo mišinio sudedamųjų dalių funkcija.

Panašus rezultatas dėl betono stiprio ir kovariančių netiesinio sąryšio gautas kiekvienai kovariantei ir atsakui nubraižius sklaidos diagramas kartu su lokalaus regresijos kreive. Šie gauti rezultatai neatsižvelgia į kitų kovariančių reikšmes, todėl jie gali tik sufleruoti apie galimą sąryšį tarp kovariantės ir atsako pilname regresijos modelyje (kuriame atsižvelgiama į kitų kovariančių reikšmes).

```
# Duomenų šaltinis
# https://archive.ics.uci.edu/ml/datasets/concrete+compressive+strength
# (https://www.kaggle.com/datasets/elikplim/concrete-compressive-strength-data-set)

library(tidyverse)
library(rsample)

concrete <- read_csv("concrete_data.csv")


concrete <- concrete %>%
  unique() %>%
  rename(strength = concrete_compressive_strength)

# Padalijama į mokymo ir testavimo aibes
set.seed(123)
concrete_split <- initial_split(concrete)
concrete_train <- training(concrete_split)
concrete_test <- testing(concrete_split)

library(corrplot)

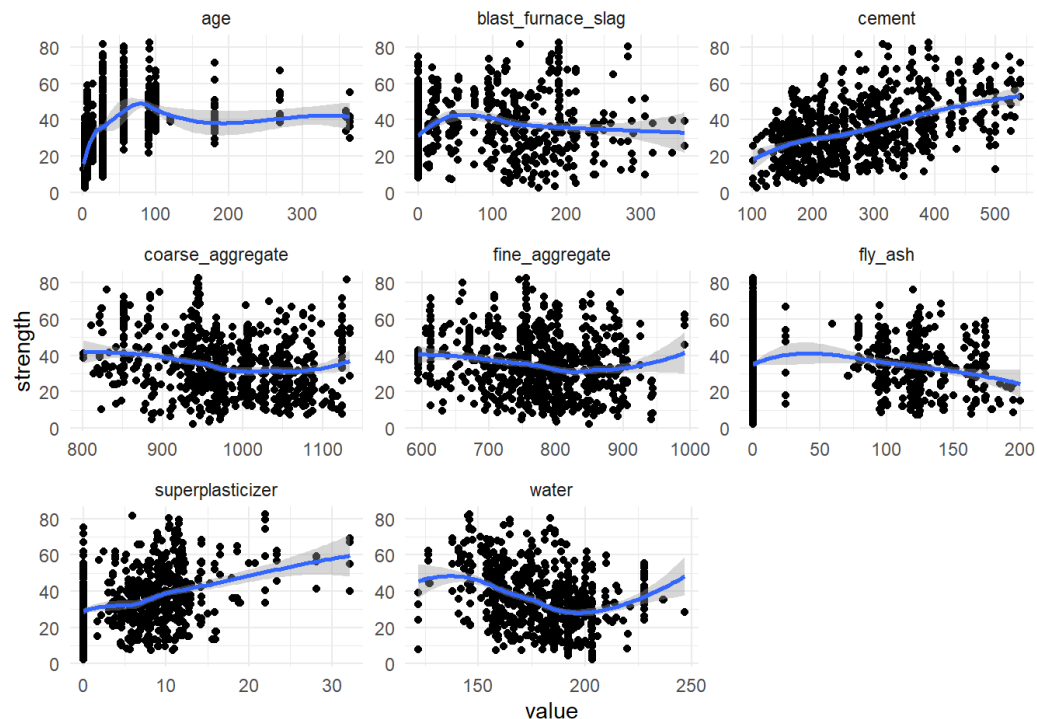
correlation_matrix <- concrete_train %>%
  cor()

corrplot(correlation_matrix, order = "original", method = "color", type = "upper", diag =
FALSE, tl.col = "black", addCoef.col = "black")
```



tarp kovariančių ir atsako matome galimus netiesinius sąryšius

```
concrete_train %>%
  pivot_longer(-strength) %>%
  ggplot(aes(value, strength)) +
  geom_point() +
  facet_wrap(vars(name), scales = "free") +
  geom_smooth() +
  theme_minimal()
```




Pirmausiajai sudarytas paprastas tiesinės regresijos modelis. Analizuojant modelio diagnostinius grafikus rastas pakankamai stiprus liekanų heteroskedatiškumas. Pagal dalinių liekanų grafikus (partial residual plot / component residual plot) rasta, kad požymiuose “water” “superplastisizer” “age” turima papildoma informacija, į kurią paprastas tiesinis modelis nesugebėjo atsižvelgti.


```
# Pirmas sudaromas regresijos modelis su vien tiesiniais
# kovariančių ir atsako sąryšiais (lyginamasis)
library(car)

baseline <- lm(strength ~ cement + blast_furnace_slag + fly_ash +
  water + superplasticizer
  + coarse_aggregate + fine_aggregate + age, data = concrete_train)


plot(baseline)
```


Fitted values
`n(strength ~ cement + blast_furnace_slag + fly_ash + water + superpla`



Theoretical Quantiles
`n(strength ~ cement + blast_furnace_slag + fly_ash + water + superpla`



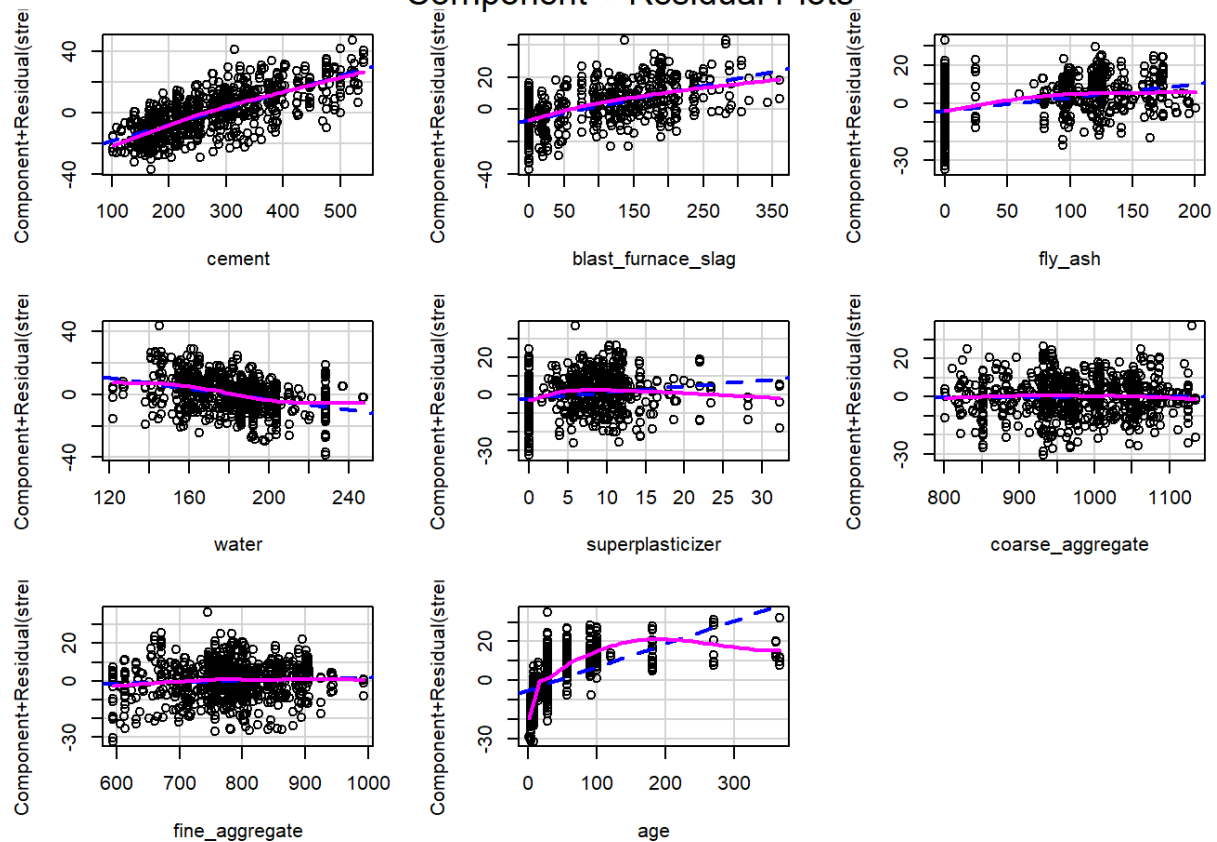
Fitted values
`n(strength ~ cement + blast_furnace_slag + fly_ash + water + superpla`



Leverage
`n(strength ~ cement + blast_furnace_slag + fly_ash + water + superpla`

`crPlots(baseline)`


Component + Residual Plots




Siekiant patobulinti gautus rezultatus, sudarytas kitas regresijos modelis, papildomai į modelį įtraukiant prieš tai paminėtų kovariančių antruosius laipsnius (polinominės regresijos modelis). Naudojantis tomis pačiomis diagnostinėmis priemonėmis, laikyta, kad prieš tai rasti modelio nukrypimai nuo teorinio sumažėjo. Naudojant hierarchinių modelių (nested models) palyginimo testą, gautas statistiškai reikšmingas antro modelio skirtumas nuo sudaryto prieš tai ($p < 0.001$).

```
# "naivus" metodas pagerinti modelį pridedant aukštesnius kovariančių laipsnius
model_polynomial <- lm(strength ~ cement + blast_furnace_slag
+ fly_ash + water + I(water^2)
+ superplasticizer + I(superplasticizer^2)
+ coarse_aggregate + fine_aggregate + age + I(age^2),
data = concrete_train
)


plot(model_polynomial)
```




n(strength ~ cement + +blast_furnace_slag + fly_ash + water + l(water'



n(strength ~ cement + +blast_furnace_slag + fly_ash + water + l(water'



Fitted values
`n(strength ~ cement + +blast_furnace_slag + fly_ash + water + l(water'`



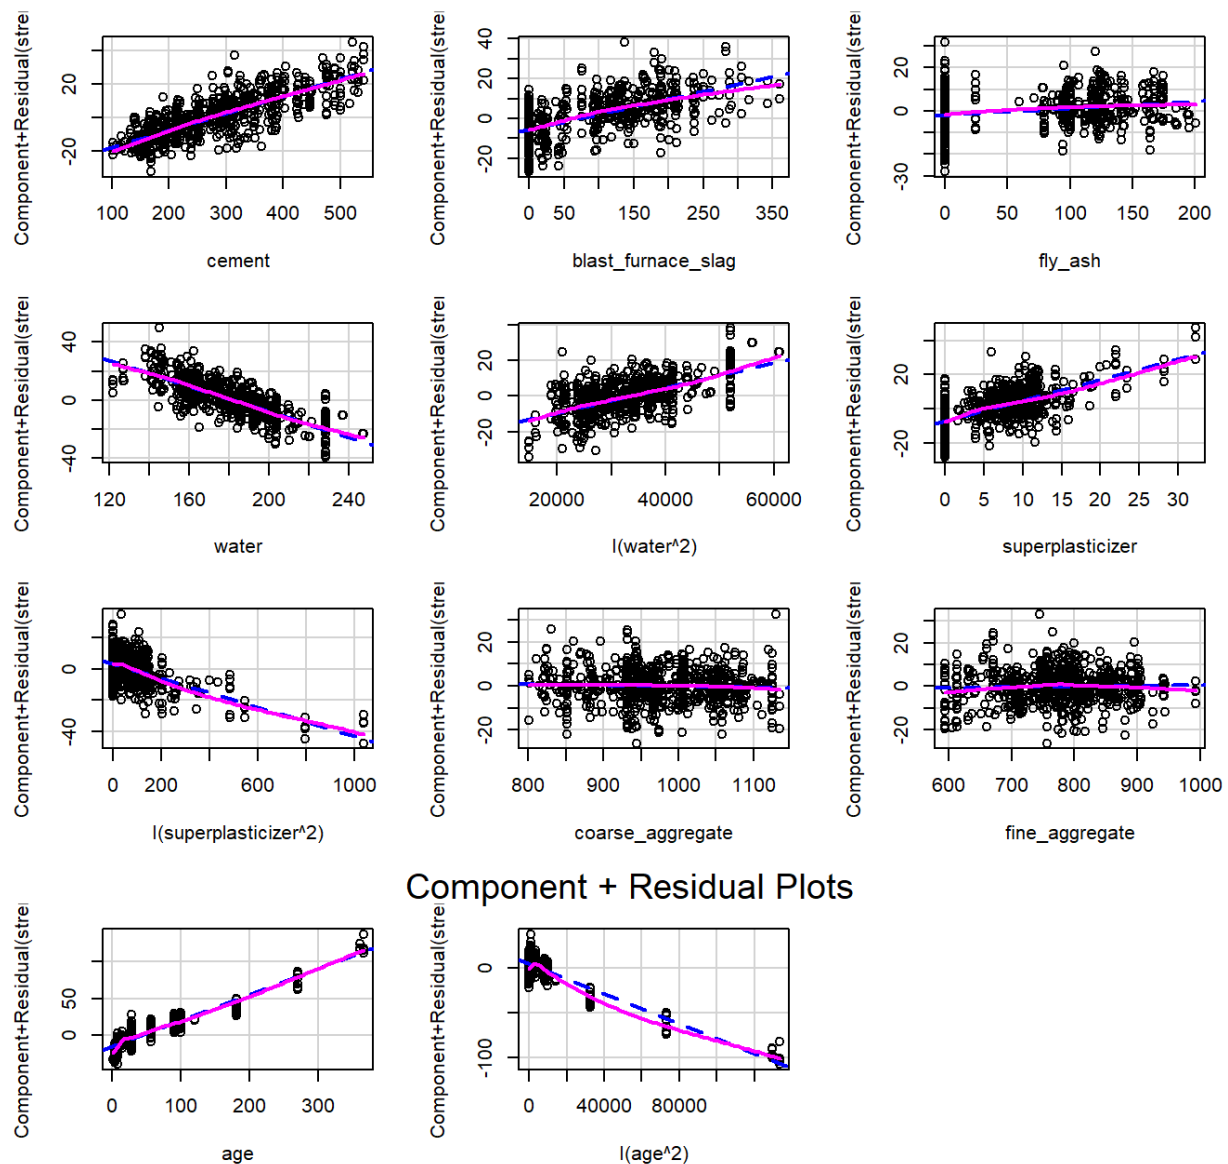
Leverage
`n(strength ~ cement + +blast_furnace_slag + fly_ash + water + l(water'`

```
summary(model_polynomial)
```

```
##
## Call:
## lm(formula = strength ~ cement + +blast_furnace_slag + fly_ash +
```

```
##      water + I(water^2) + superplasticizer + I(superplasticizer^2) +
##      coarse_aggregate + fine_aggregate + age + I(age^2), data = concrete_train)
##
## Residuals:
##      Min        1Q    Median        3Q        Max
## -26.172  -4.597   0.047   4.843  33.480
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    4.325e+01  2.519e+01   1.717  0.08639 .
## cement         1.025e-01  7.386e-03  13.870 < 2e-16 ***
## blast_furnace_slag 7.631e-02  8.966e-03   8.511 < 2e-16 ***
## fly_ash        3.166e-02  1.147e-02   2.761  0.00591 **
## water         -4.414e-01  1.716e-01  -2.571  0.01032 *
## I(water^2)      6.992e-04  4.763e-04   1.468  0.14259
## superplasticizer 1.209e+00  1.494e-01   8.095 2.35e-15 ***
## I(superplasticizer^2) -4.655e-02  5.935e-03  -7.843 1.53e-14 ***
## coarse_aggregate -5.052e-03  8.459e-03  -0.597  0.55051
## fine_aggregate   3.445e-03  9.486e-03   0.363  0.71660
## age            3.527e-01  1.255e-02  28.095 < 2e-16 ***
## I(age^2)       -8.310e-04  4.081e-05 -20.364 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 7.825 on 741 degrees of freedom
## Multiple R-squared:  0.7635, Adjusted R-squared:  0.76
## F-statistic: 217.5 on 11 and 741 DF,  p-value: < 2.2e-16

crPlots(model_polynomial)
```



Component + Residual Plots

```
# modelis reikšmingai skiriasi nuo modelio be aukštesnio laipsnio narių
anova(baseline, model_polynomial)
```

```
## Analysis of Variance Table
##
```

```
## Model 1: strength ~ cement + blast_furnace_slag + fly_ash + water + superplasticizer +
## coarse_aggregate + fine_aggregate + age
```

```
## Model 2: strength ~ cement + blast_furnace_slag + fly_ash + water + I(water^2) +
## superplasticizer + I(superplasticizer^2) + coarse_aggregate +
## fine_aggregate + age + I(age^2)
```

```
## Res.Df RSS Df Sum of Sq F Pr(>F)
## 1 744 75286
## 2 741 45374 3 29912 162.83 < 2.2e-16 ***
```

```
## ---
```

```
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

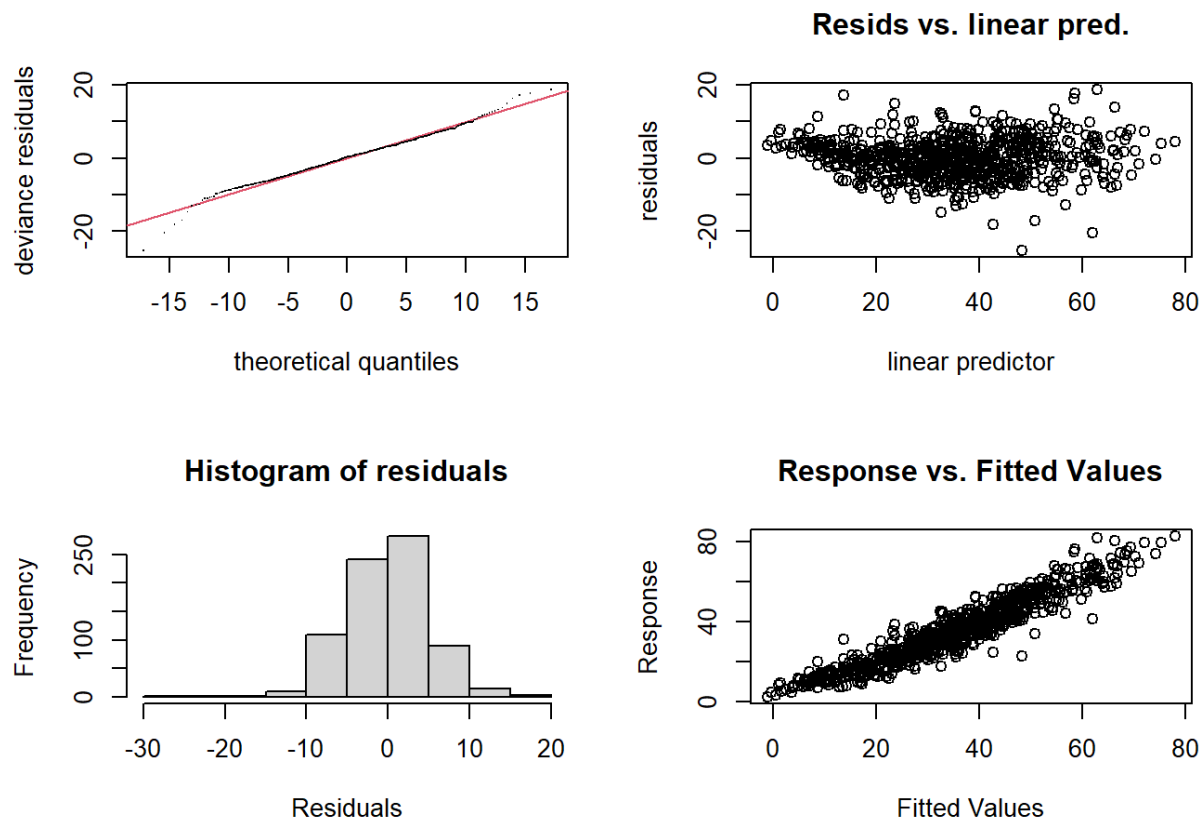
Siekiant tiksliau modeliuoti betono stiprį negu polinominės regresijos modeliu pasirinkta sudaryti apibendrintą adityvų regresijos modelį, naudojant glodniaisius splainus. Šiam tikslui pasitelkta *mgcv* biblioteka. Naudojant *gam* funkciją iš šios bibliotekos, parametras λ parenkamas automatiškai, naudojant generalized cross validation. Imant numatytąjį mazgų skaičių kiekvienai kovariantei, diagnostiniuose grafikuose stiprių nukrypimų nuo modelio prielaidų nerasta, tačiau tiek statistiniais testais, tiek naudojantis modelio kovariančių efektų grafikais pastebėta, kad pradinis mazgų skaičius gali būti per mažas tinkamai įvertinti sąryšius tarp kovariančių ir atsako (stipriausiai tai matoma su kovariante „coarse_aggregate“)

```
c: 29.5 on 10 and 742 DF, p-value: < 2.2e-16
```

```
library(mgcv)
library(gratia)
# Alternatyvus modelis: apibendrintas adityvus modelis su glodniaisiais splainais

# Lambda parametras parenkamas automatiškai pagal generalized cross-validation
model_gam <- gam(strength ~ s(cement) + s(blast_furnace_slag) + s(fly_ash)
  + s(water) + s(superplasticizer)
  + s(coarse_aggregate) + s(fine_aggregate) + s(age),
  data = concrete_train,
  select = TRUE
)

gam.check(model_gam)
```




```

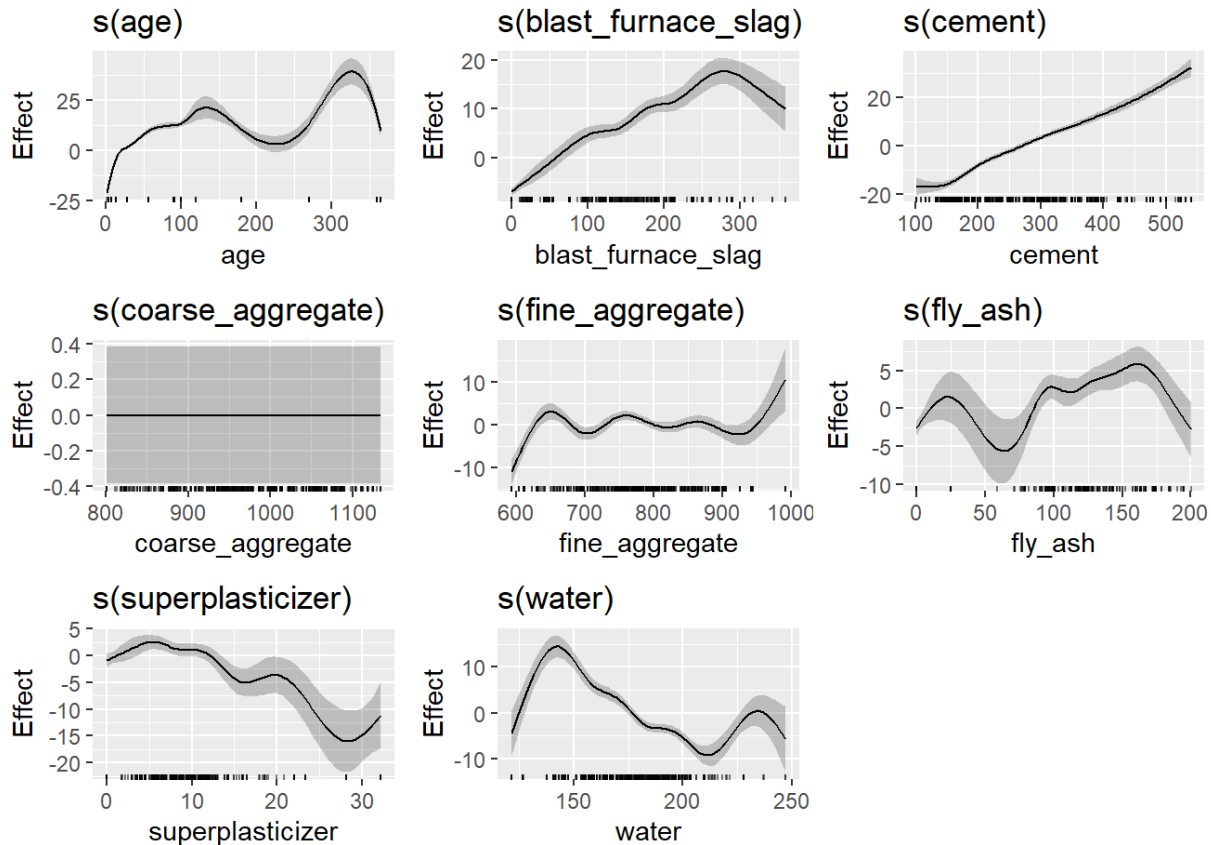
##
## Method: GCV   Optimizer: magic
## Smoothing parameter selection converged after 128 iterations.
## The RMS GCV score gradient at convergence was 0.0003962093 .
## The Hessian was not positive definite.
## Model rank = 73 / 73
##
## Basis dimension (k) checking results. Low p-value (k-index<1) may
## indicate that k is too low, especially if edf is close to k'.
##
##           k'      edf k-index p-value
## s(cement)      9.00e+00 6.85e+00   0.91  0.020 *
## s(blast_furnace_slag) 9.00e+00 6.72e+00   0.96  0.085 .
## s(fly_ash)      9.00e+00 7.16e+00   1.01  0.655
## s(water)        9.00e+00 8.38e+00   0.94  0.005 **
## s(superplasticizer) 9.00e+00 7.85e+00   0.93  0.030 *
## s(coarse_aggregate) 9.00e+00 2.33e-07   0.86 <2e-16 ***
## s(fine_aggregate) 9.00e+00 8.51e+00   0.87 <2e-16 ***
## s(age)          9.00e+00 7.99e+00   1.06  0.950
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

summary(model_gam)

##
## Family: gaussian
## Link function: identity
##
## Formula:
## strength ~ s(cement) + s(blast_furnace_slag) + s(fly_ash) + s(water) +
##           s(superplasticizer) + s(coarse_aggregate) + s(fine_aggregate) +
##           s(age)
##
## Parametric coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept)  34.7507     0.1955   177.7 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Approximate significance of smooth terms:
##             edf Ref.df      F p-value
## s(cement)      6.853e+00     9 100.841 <2e-16 ***
## s(blast_furnace_slag) 6.723e+00     9  50.595 <2e-16 ***
## s(fly_ash)      7.162e+00     9   6.798 <2e-16 ***
## s(water)        8.383e+00     9  29.612 <2e-16 ***
## s(superplasticizer) 7.851e+00     9   7.709 <2e-16 ***
## s(coarse_aggregate) 2.332e-07     9   0.000  0.958
## s(fine_aggregate)  8.514e+00     9   9.957 <2e-16 ***
## s(age)          7.986e+00     9 266.120 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## R-sq.(adj) =  0.887   Deviance explained = 89.5%
## GCV = 31.031   Scale est. = 28.787     n = 753

draw(model_gam)





```



Padidinus mazgų skaičių ir naudojant visas prieš tai aprašytas diagnostikas nerasta stiprių nukrypimų nuo teorinio modelio. Gautame modelyje visos kovariantės reikšmingos, taip pat gautas statistiškai reikšmingas skirtumas nuo modelio, naudojančio mažesnį (numatytąjį) mazgų skaičių ($p < 0.001$). Siekiant palyginti prieš tai sudarytą daug paprastesnį polinominės regresijos ir gautą glodniųjų splineų modelį, abiem iš jų nubraižyti kovariančių efektų grafikai. Matoma, kad apibendrinto adityvaus modelio atveju gauti daug sudėtingesni sąryšiai tarp kovariančių ir atsako.

```
# Padidinamas mazgų skaičius
model_gam2 <- gam(strength ~ s(cement) + s(blast_furnace_slag, k = 20) + s(fly_ash, k = 20)
  + s(water, k = 20) + s(superplasticizer, k = 20)
  + s(coarse_aggregate, k = 20) + s(fine_aggregate, k = 20) + s(age, k = 10),
data = concrete_train,
select = TRUE
)

gam.check(model_gam2)
```



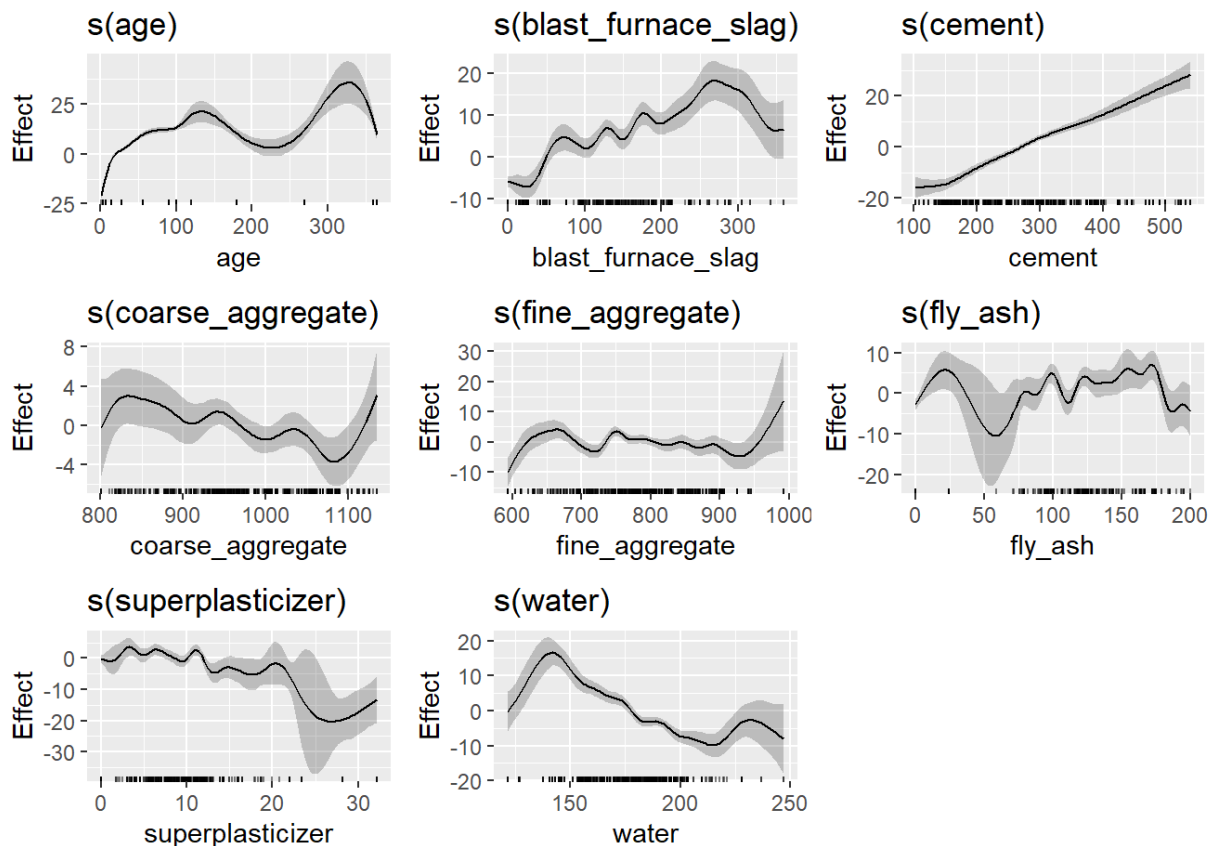
```
##
## Method: GCV   Optimizer: magic
## Smoothing parameter selection converged after 82 iterations.
## The RMS GCV score gradient at convergence was 0.0004353583 .
## The Hessian was not positive definite.
## Model rank = 133 / 133
##
## Basis dimension (k) checking results. Low p-value (k-index<1) may
## indicate that k is too low, especially if edf is close to k'.
##
##           k'   edf k-index p-value
## s(cement)      9.00  6.19   0.99  0.375
## s(blast_furnace_slag) 19.00 13.96   1.03  0.845
## s(fly_ash)     19.00 15.09   1.05  0.940
## s(water)       19.00 12.16   1.01  0.635
## s(superplasticizer) 19.00 16.00   0.97  0.220
## s(coarse_aggregate) 19.00  9.28   0.96  0.105
## s(fine_aggregate)  19.00 15.01   0.95  0.055 .
## s(age)         9.00  8.18   1.07  0.990
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

summary(model_gam2)

##
## Family: gaussian
## Link function: identity
##
## Formula:
```

```
## strength ~ s(cement) + s(blast_furnace_slag, k = 20) + s(fly_ash,
##      k = 20) + s(water, k = 20) + s(superplasticizer, k = 20) +
##      s(coarse_aggregate, k = 20) + s(fine_aggregate, k = 20) +
##      s(age, k = 10)
##
## Parametric coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  34.7507      0.1821   190.9  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Approximate significance of smooth terms:
##              edf Ref.df      F p-value
## s(cement)      6.188     9 23.149 < 2e-16 ***
## s(blast_furnace_slag) 13.959    19  7.039 < 2e-16 ***
## s(fly_ash)     15.091    19  3.670 < 2e-16 ***
## s(water)      12.163    19  8.275 < 2e-16 ***
## s(superplasticizer) 16.005    19  3.923 < 2e-16 ***
## s(coarse_aggregate)  9.276    19  1.151 0.00268 **
## s(fine_aggregate)  15.014    19  5.826 < 2e-16 ***
## s(age)         8.177     9 298.256 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## R-sq.(adj) = 0.902   Deviance explained = 91.5%
## GCV = 28.651   Scale est. = 24.965    n = 753

draw(model_gam2)
```



```
# modelis statistiškai reikšmingai skiriasi nuo modelio su mažesniu mazgų skaičiumi
anova(model_gam, model_gam2, test="F")
```

```
## Analysis of Deviance Table
```

```
##
```

```
## Model 1: strength ~ s(cement) + s(blast_furnace_slag) + s(fly_ash) + s(water) +
##      s(superplasticizer) + s(coarse_aggregate) + s(fine_aggregate) +
##      s(age)
```

```
## Model 2: strength ~ s(cement) + s(blast_furnace_slag, k = 20) + s(fly_ash,
##      k = 20) + s(water, k = 20) + s(superplasticizer, k = 20) +
##      s(coarse_aggregate, k = 20) + s(fine_aggregate, k = 20) +
##      s(age, k = 10)
```

```
##      Resid. Df Resid. Dev      Df Deviance      F      Pr(>F)
## 1      694.30      20108
## 2      643.57      16380 50.732   3728.2 2.9437 3.48e-10 ***
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
# modelio palyginimas su prieš tai sudarytu polinominės regresijos modeliu
```

```
library(effects)
```

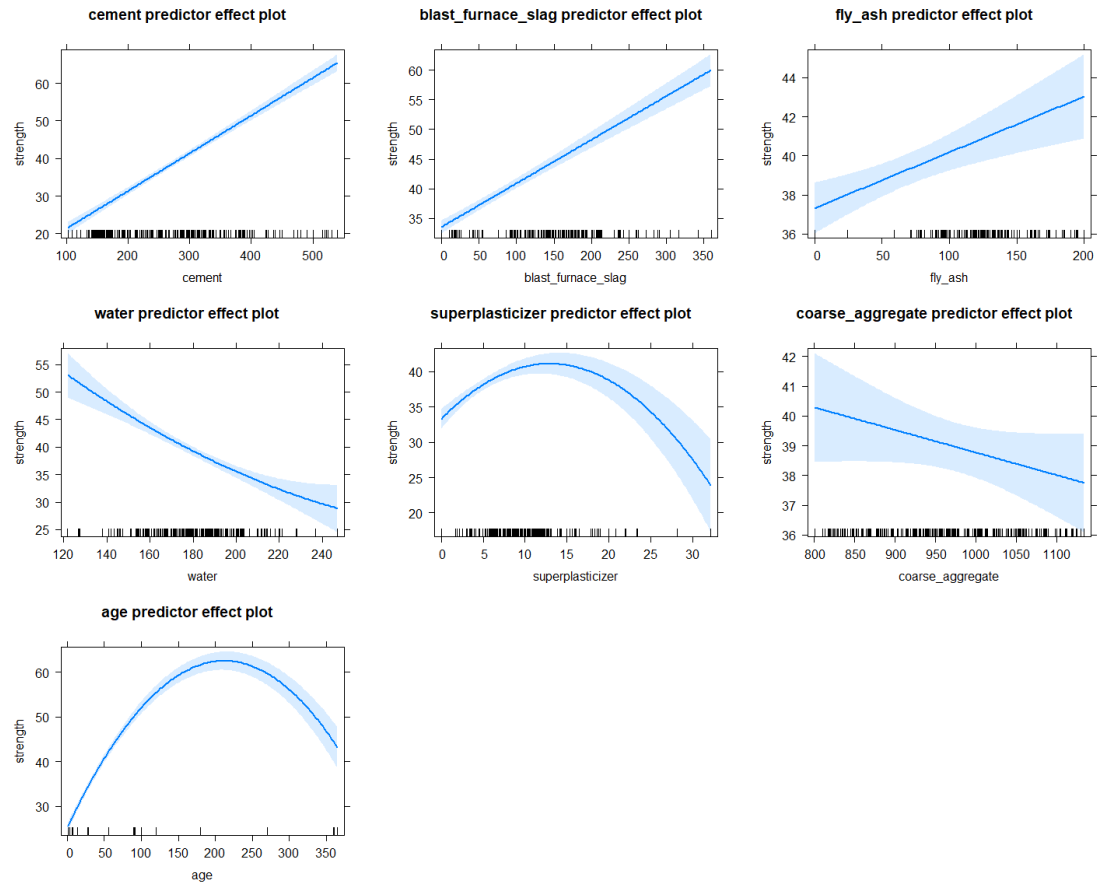
```
AIC(model_polynomial)
```

```
## [1] 5247.325
```

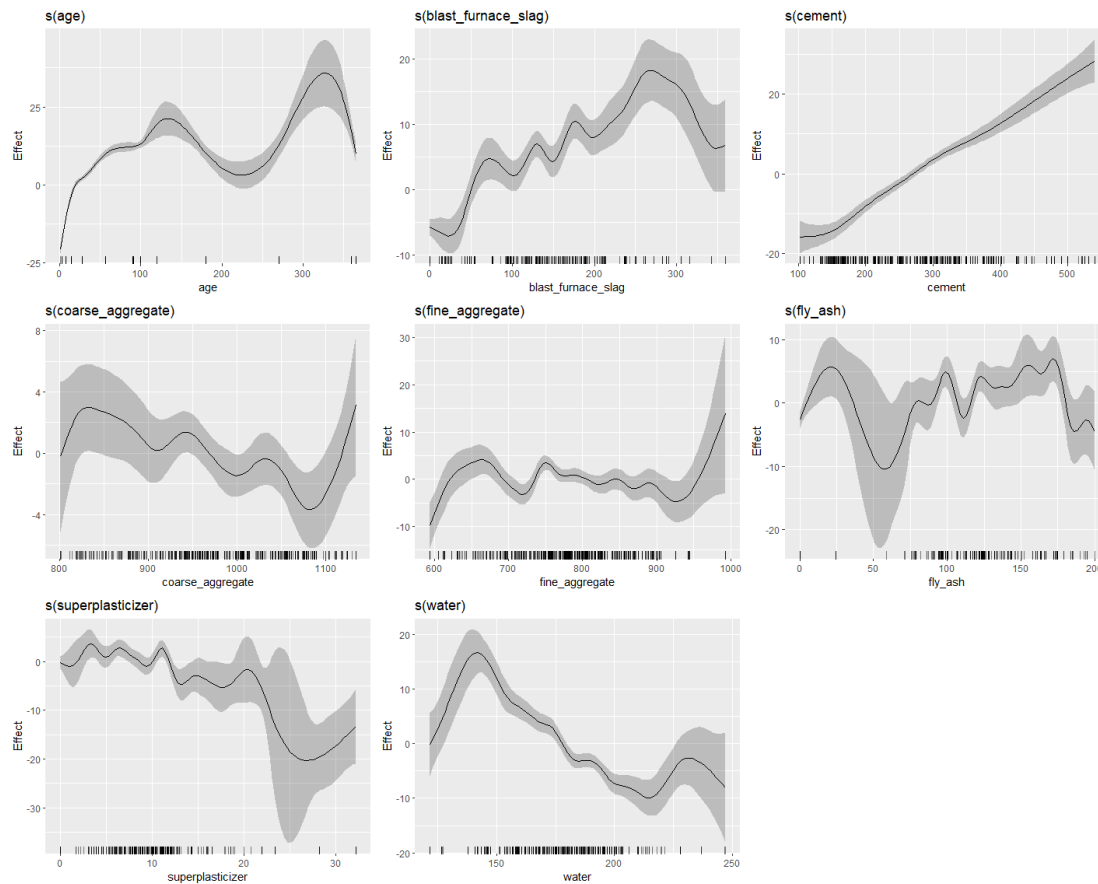
```
AIC(model_gam2)
```

```
## [1] 4651.725
```

```
plot(predictorEffects(model_polynomial))
```



```
draw(model_gam2)
```



Kaip pastebėta naudojantis praėjusiais grafikai, glodniųjų splineų modelių gauti daug sudėtingesni sąryšiai negu gauti naudojantis polinominės regresijos modelių. Nors sudarytame modelyje naudoti glodnieji splineai, kurie dėl glodinimo baudos apsaugo nuo per didelio modelio prisitaikymo mokymo duomenims, pasirinkta panaudoti testavimo aibę patikrinti, ar modelis tikrai nepersimokė ir tuo pačiu metu įvertinti visų sudarytų modelių prognozavimo kokybę. Gauta, kad tiek pagal vidutinę absoliučią paklaidą (Mean Absolute Error), tiek matuojant vidutinę kvadratinę paklaidą ((Root) Mean Square Error), glodniųjų splineų modelių gauti žymiai geresni rezultatai už prieš tai sudarytus modelius (paklaidos daugiau nei dvigubai mažesnės lyginant su paprastu tiesiniu modeliu, apie 50% mažesnės lyginant su polinominiu modeliu). Grafiškai modelių prognozės palygintos naudojant prognozuotų ir tikrų reikšmių sklaidos diagramas. Matoma, kad glodniųjų splineų modelių gauta daug mažesnė sklaida aplink prognozuotas ir tikras reikšmės lygybės tiesę lyginant su kitais modeliais.

```
# Nors naudoti glodnieji splineai, naudojant testavimo aibę patikrinama ar kažkur nebuvo padaryta klaidų ir
# modelis tikrai nepersimokė
library(yardstick)
```

```
concrete_test <- concrete_test %>%
  mutate(predicted_baseline = predict(baseline, concrete_test),
         predicted_polynomial = predict(model_polynomial,concrete_test),
         predicted_gam = predict(model_gam2,concrete_test))
```

```

set <- metric_set(rmse,mae)
set(concrete_test, strength, predicted_baseline)

## # A tibble: 2 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>      <dbl>
## 1 rmse    standard      11.1
## 2 mae     standard       8.79

set(concrete_test, strength, predicted_polynomial)

## # A tibble: 2 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>      <dbl>
## 1 rmse    standard       9.08
## 2 mae     standard       6.76


set(concrete_test, strength, predicted_gam)

## # A tibble: 2 x 3
##   .metric .estimator .estimate
##   <chr>   <chr>      <dbl>
## 1 rmse    standard       5.47
## 2 mae     standard       4.28

# tiek pagal MAE, tiek pagal RMSE naudojant gam modelį gaunami geresni rezultatai

# Modelių prognozių palyginimas
concrete_test %>%
  pivot_longer(c(predicted_gam, predicted_polynomial,predicted_baseline)) %>%
  ggplot(aes(strength, value)) +
  geom_point() +
  facet_wrap(vars(name)) +
  geom_abline(color = "red", size = 1.25) +
  labs(x = "Actual", y = "Predicted") +
  theme_minimal()

```



Išvados:

Atlikus pirminę duomenų aibės analizę rasta, kad betono stipris gali netiesiškai priklausyti nuo jo mišinį sudarančių medžiagų, todėl laikyta, kad paprastas tiesinės regresijos modelis gali būti netinkamas prognozuoti betono stiprį.

Siekiant turėti palyginamąjį modelį sudarytas paprastas tiesinės regresijos modelis. Kaip vienas iš būdų pagerinti modelį buvo pasirinkta polinominė regresija. Į modelį buvo įtraukti antrieji laipsniai tų kintamųjų, kuriuose pagal tiesinės regresijos diagnostinius grafikus rasta neišnaudotos informacijos. Pasitelkiant grafines modelių diagnostikas ir statistinius testus laikyta, kad antru modeliu gaunami geresni rezultatai.

Siekiant dar labiau pagerinti rezultatus (ir parodyti, kad aukštesnių laipsnių įtraukimas į paprastą tiesinį modelį nėra pakankamas tikslioms prognozėms gauti) sudarytas apibendrintas adityvus regresijos modelis, naudojantis glodniuosius splainus. Pirmiausia naudotas numatytasis mazgų skaičius, tačiau naudojant modelio diagnostikas pasirinkta šį skaičių padidinti. Parinkus didesnį mazgų skaičių modelio diagnostikose beveik nerasta nukrypimų. Visos modelyje naudotos kovariantės modelyje statistiškai reikšmingos.

Testavimo aibė panaudota įvertinti visų šių modelių gebėjimą prognozuoti reikšmes. Kaip ir tikėtasi, geriausi rezultatai gauti naudojant glodniųjų splainų modelį (paklaidos pagal dvi skirtingas matavimo metrikas daugiau nei dvigubai mažesnės už tiesinį ir apie 50% mažesnės už polinominį modelį). Dėl šios priežasties daroma išvada, kad sudarytas glodniųjų splainų apibendrintas adityvus tinkamas prognozuoti betono stiprį, be to šiuo modeliu gaunami ryškiai geresni rezultatai negu naudojant paprastesnį metodą netiesiniams sąryšiams tarp atsako ir kovariančių modeliuoti, kuriuo paprastas tiesinės regresijos modelis papildomas kovariančių aukštesniais laipsniais.